

Gradient matching: interval zaupanja za hitro rezanje kandidatnih enačb

Kako iz ENE, poceni izvedbe gradient matchinga (malo naključno vzorčenih testnih točk, GP interpolant namesto resničnega x) dobiti pošten interval zaupanja za pravo napako kandidatne strukture, in ga uporabiti za rezanje očitno slabih kandidat med strukturnim iskanjem. Spremljevalni dokument k [gradient-matching.md](#) - ista notacija ($\hat{x}$, $e(t)$, ℓ , GP definicije), tu ponovljena samo na kratko, s sklicem nazaj za polno izpeljavo.

0. Notacija (nadaljevanje [gradient-matching.md](#))

Za kandidatno enačbo $x' = F(x, t, \theta)$, GP interpolant $\hat{x}$ (fiksni, glej [gradient-matching.md](#) Definicija 1.2) in testno točko t_i :

- $r(t_i, \theta) := \hat{x}'(t_i) - F(\hat{x}(t_i), t_i, \theta)$ - gradient-matching residual (Definicija 2.1 v [gradient-matching.md](#)),
- $\rho_i(\theta) := g(r(t_i, \theta))$ - penalty ($g(r) = |r|$ za L1, $g(r) = r^2$ za L2),
- $L_n(\theta) := \frac{1}{n} \sum_{i=1}^n \rho_i(\theta)$ - gradient-matching izguba na n naključno vzorčenih testnih točkah (**ne** nujno enaka mreži $t_1, \dots, t_m$ iz [gradient-matching.md](#) §2 - tu n namenoma majhen, izbran za hiter presejalni prehod),
- $\hat{\theta}_n := \arg \min_{\theta} L_n(\theta)$,
- $\sigma^2(t) := \text{Var}[X(t) \mid \text{podatki}]$, $\sigma_d^2(t) := \text{Var}[X'(t) \mid \text{podatki}]$ - GP posteriorni varianci stanja in odvoda (glej [gradient-matching.md](#) Definicija 1.2'),
- $F_x(t, \theta) := \partial_x F(\hat{x}(t), t, \theta)$ - Jacobijan desne strani po stanju,
- ℓ - korelacijska dolžina GP-jevega jedra.

Cilj: iz $L_n(\hat{\theta}_n)$ (poceni, na malo točkah) oceniti interval, v katerem se z visoko verjetnostjo nahaja "polna" napaka te strukture - tista, ki bi jo dobili z vsemi razpoložljivimi $N \gg n$ točkami IN z resničnim x namesto $\hat{x}$.

1. Dva neodvisna vira negotovosti

Ključno je ločiti dve POPOLNOMA RAZLIČNI vprašanji.

Vir A - vzorčenje. Katerih n od razpoložljivih N točk smo izbrali? Vprašanje o *deterministični* količini $\rho_i(\theta)$ pri fiksnem $\hat{x}$ - naključnost izhaja samo iz tega, kateri t_i so pristali v vzorcu.

Vir B - interpolacija. Je resnični $X(t_i)$ sploh enak $\hat{x}(t_i)$? Ne vprašanje o vzorčenju - t_i je fiksni, naključnost je v GP-jevem POSTERIORJU o tem, kje je resnično stanje.

Pomembno: ne gre za "ponovi cel eksperiment z novim šumom" (frekventistična varianca cenilke čez hipotetične ponovitve podatkov) - $\hat{x}$ ostaja skozi vse spodaj fiksni, izračunan enkrat iz ENEGA, že opazovanega nabora podatkov. Oba vira spodaj sta o tem istem, fiksnem naboru.

2. Vzorčna komponenta (Vir A)

Definicija 2.1 (vzorčna varianca).

$$s^2(\theta) = \frac{1}{n-1} \sum_{i=1}^n (\rho_i(\theta) - \bar{\rho}(\theta))^2$$

(Besselov popravek $n - 1$, nepristranska cenilka.)

Trditev 2.2 (CLT za L_n). Za dovolj velik n (in ne prehudo poševne ρ_i) je $L_n(\theta)$ približno normalno porazdeljen okoli svoje "polne" (N -točkovne) vrednosti:

$$\text{Var}_A[L_n(\theta)] \approx \frac{s^2(\theta)}{n} \left(1 - \frac{n}{N}\right)$$

(popravek za končno populacijo $(1 - n/N)$ zanemarljiv, kadar $n \ll N$). To je natanko Centralni limitni izrek: povprečje n (grobo neodvisnih) spremenljivk je približno normalno NE GLEDE na obliko posameznih ρ_i .

Opomba (neodvisnost ni samoumevna). Če so testne točke blizu skupaj, GP-jeva korelacija med $\hat{x}(t_i), \hat{x}(t_j)$ pada kot $e^{-\Delta t^2/2\ell^2}$ in ni zanemarljiva. Rešitev: testne točke naključno vzorčimo ČEZ interval dolžine $\gg \ell$ - tedaj je razmik med naključnima točkama tipično $\Delta t \gg \ell$, neodvisnost pa velja praktično zastonj.

3. Interpolacijska komponenta (Vir B)

GP posterior natanko pove, kako negotov je $(X(t_i), X'(t_i))$ glede na podatke:

$$\begin{pmatrix} X(t_i) \\ X'(t_i) \end{pmatrix} \Big|_{\text{podatki}} \sim \mathcal{N} \left(\begin{pmatrix} \hat{x}(t_i) \\ \hat{x}'(t_i) \end{pmatrix}, \begin{pmatrix} \sigma^2(t_i) & c(t_i) \\ c(t_i) & \sigma_d^2(t_i) \end{pmatrix} \right)$$

σ^2, σ_d^2 poznamo (`GP1dim.std`, `GP1dim.std_derivative`, glej `odestimate`). Manjka prečni člen $c(t_i) := \text{Cov}[X(t_i), X'(t_i)]$ - kovarianca med stanjem in odvodom PRI ISTI TOČKI.

Trditev 3.1 (prečni člen). Za stacionarno jedro je apriorna kovarianca med $f(t)$ in $f'(t)$ pri isti t natanko 0 (odvod sode funkcije pri 0 je 0). Posteriora ni nujno 0 - oba se pogojujeta na iste podatke:

$$c(t) = -v(t)^\top v'(t)$$

kjer sta $v(t) = L^{-1}k(t, X_{\text{train}})^\top$, $v'(t) = L^{-1}\partial_t k(t, X_{\text{train}})^\top$ natanko projekciji, ki ju `std/std_derivative` že računata. En dodaten skalarni produkt - nič novega ni treba zgraditi.

Dokaz (skica). Splošna formula posteriorne kovariance: $\text{Cov}_{\text{post}}[f(t), g(t')] = \text{Cov}_{\text{prior}}[f(t), g(t')] - v_f(t)^\top v_g(t')$. Za $f = \text{id}$, $g = \text{odvod}$, $t' = t$: prvi člen izgine (stacionarnost + sodost jedra), ostane drugi. ■

Delta metoda - propagacija skozi F . Linearizacija (ista kot povsod v `gradient-matching.md` §1.4 - velja natanko toliko, kolikor je $\sigma(t_i)$ res majhna, tj. testne točke so izbrane v "dobrem" delu domene):

$$r_{\text{true}}(t_i) - r(t_i) \approx \delta X'(t_i) - F_x(t_i, \theta) \cdot \delta X(t_i)$$

Linearna kombinacija skupno-Gaussovih $(\delta X, \delta X')$ je spet Gaussova, z varianco (skalarno stanje):

$$\tau^2(t_i) := \sigma_d^2(t_i) - 2F_x(t_i, \theta) c(t_i) + F_x(t_i, \theta)^2 \sigma^2(t_i)$$

Za penalty $\rho = g(r)$, z verižnim pravilom $\delta \rho \approx g'(r) \cdot \delta r$:

penalty	$g(r)$	$\text{Var}[\delta\rho_i]$
L1	$ r $	$\tau^2(t_i)$
L2	r^2	$4 r(t_i)^2 \tau^2(t_i)$

Trditev 3.2 (interpolacijska varianca izgube). Ker so testne točke (Vir A) izbrane narazen ($\Delta t \gg \ell$), so tudi $\delta\rho_i$ med sabo neodvisne - vsota neodvisnih Gaussovih je EKSAKTNO Gaussova (brez dodatnega CLT-približka na tem koraku):

$$\text{Var}_B[L_n(\theta)] \approx \frac{1}{n^2} \sum_{i=1}^n g'(r_i)^2 \tau^2(t_i)$$

4. Skupna negotovost in interval zaupanja

Vir A in Vir B sta pojmovno ločena (eno je "katere točke", drugo "je $\hat{x}$ enak resničnemu x pri fiksni točki"), in oba prispevata s pričakovano vrednostjo nič prvega reda (linearizacija okoli posteriorne SREDINE, po definiciji brez pristranskosti) - zato se preprosto seštejeta.

Trditev 4.1 (skupna varianca in interval zaupanja).

$$\text{Var}[L_n(\hat{\theta}_n)] \approx \text{Var}_A + \text{Var}_B = \frac{s^2}{n} + \frac{1}{n^2} \sum_{i=1}^n g'(r_i)^2 \tau^2(t_i)$$

$$\text{SE} = \sqrt{\text{Var}[L_n(\hat{\theta}_n)]}$$

$$\text{interval zaupanja} = L_n(\hat{\theta}_n) \pm t_{n-1}(1 - \alpha/2) \cdot \text{SE}$$

Studentova t_{n-1} namesto normalne z , ker je n namenoma majhen - konsistentno konservativno (širše, ne ožje, kot pri velikem n).

5. Algoritem (za eno kandidatno strukturo)

1. Fitaj GP $\hat{x}(t)$ na podatke (enkrat, deli se med vsemi kandidatkami).
2. Izberi interval z nizko, enakomerno $\sigma(t)$ (izven vrzeli v podatkih), dolžine $\gg \ell$.
3. Naključno vzorči n testnih točk znotraj tega intervala.
4. Fitaj hitro: $\hat{\theta}_n = \arg \min_{\theta} L_n(\theta)$.
5. Iz že-obstojećih rezidualov ρ_i izračunaj $\bar{\rho} (= L_n)$ in s^2 (Vir A).
6. Za vsak t_i izračunaj $F_x(t_i, \hat{\theta}_n)$, $\sigma(t_i)$, $\sigma_d(t_i)$, $c(t_i) \Rightarrow \tau^2(t_i)$ (Vir B).
7. Sestavi $\text{SE} = \sqrt{s^2/n + \frac{1}{n^2} \sum g'(r_i)^2 \tau^2(t_i)}$.
8. Interval: $L_n(\hat{\theta}_n) \pm t_{n-1}(1 - \alpha/2) \cdot \text{SE}$.

Rezanje kandidat. Strukturo A odstrani v prid strukturi B samo, če se intervala NE prekrivata:

$$L_n^A - t^* \text{SE}^A > L_n^B + t^* \text{SE}^B \implies \text{odstrani A}$$

Kandidatke, ki eksplodirajo za VSAK θ (loss ogrožen na peščici razpršenih θ , brez optimizacije), odstrani že PRED tem korakom - brezplačen, ločen prvi filter.

6. Omejitve

- Vse zgoraj je delta metoda (linearizacija prvega reda) - velja natanko toliko, kolikor je $\sigma(t_i)$ res majhna na izbranem intervalu. Drugi red ($F_{xx} \cdot \sigma^2$) daje majhno dodatno pristranskost, ki tu ni zajeta - empirično (Bled) je ta zunaj vrzeli v podatkih ~1 % linearnega člena, znotraj vrzeli pa lahko preseže 100 % (glej [gradient-matching.md](#) §1.4 za isti fenomen).
- Kombinirana pivotalna količina (Vir A ocenjen iz vzorca, Vir B znan analitično) ni strogo Studentova t - uporaba t_{n-1} na SKUPNEM SE je praktičen, rahlo konservativen približek, ne eksakten rezultat.
- Namen je hitro in VARNO rezanje očitno slabih kandidat, ne natančna statistika - raje širši (konservativen) SE kot preozek. Napačno zavržena dobra kandidatka je draga napaka; nekaj krogov dlje obdržana slaba kandidatka je poceni.