

Gradient matching: matematične osnove

Analiza napake, identifikabilnosti in občutljivosti na šum pri ocenjevanju parametrov ODE iz točkovnega (ne integriranega) ujemanja z zašumljenimi podatki. Spremljevalni dokument k [integral-matching.md](#) - iste definicije, ista notacija, kjer se da neposredno primerljivo.

Kako brati ta učbenik

Ista konvencija kot [integral-matching.md](#): vsako poglavje uvede pojem, ga formalno definira, poda vir, nato ga takoj uporabi v izpeljavi. Kjer trditev ni strogo dokazana, ampak je hevristični (dimenzijski) argument, je to eksplicitno označeno. Kjer se pojem natančno ujema z definicijo v [integral-matching.md](#), je ponovljen na kratko (za samostojnost dokumenta), s sklicem nazaj za polno izpeljavo.

Notacija je ista kot v [integral-matching.md](#):

- $x(t) \in \mathbb{R}^d$ - prava (neznana) rešitev ODE,
- $c \in \mathbb{R}^p$ - vektor parametrov, c_0 njegova prava vrednost,
- $F : \mathbb{R}^d \times \mathbb{R} \times \mathbb{R}^p \rightarrow \mathbb{R}^d$ - desna stran enačbe, $x' = F(x, t, c)$,
- $y_i = x(t_i) + \eta_i$, $\eta_i \sim$ šum - opazovani podatki,
- $\hat{x}(t)$ - GP posteriorna povprečna funkcija, ocenjena iz $\{(t_i, y_i)\}$,
- $t_0 < t_1 < \dots < t_n$ - mreža časov.

Novo v tem dokumentu:

- $\hat{x}'(t)$ - GP posteriorna povprečna funkcija ODVODA (definirana spodaj, §1.2),
- $r_i(c) := \hat{x}'(t_i) - F(\hat{x}(t_i), t_i, c)$ - gradient-matching residual v točki t_i ,
- ℓ - korelacijska dolžina (lengthscale) GP-jevega jedra (glej [integral-matching.md](#) §1.2),
- ε - enakomerna meja za $\|\hat{x}(t) - x(t)\|$ (glej §1.4 spodaj, enako kot prej),
- ε' - enakomerna meja za $\|\hat{x}'(t) - x'(t)\|$ (NOVO - glavni predmet tega dokumenta).

1. Gradniki

1.1 Problem ocenjevanja parametrov ODE

Enak inverzni problem kot v [integral-matching.md](#) §1.1: dana družina ODE $x' = F(x, t, c)$ in zašumljena opazovanja $y_i = x(t_i) + \eta_i$; cilj je oceniti c_0 . Isti Hadamardov okvir (dobro/slabo postavljeni problemi) se uporabi spodaj v §6.2 - tokrat na operaciji ODVAJANJA, ne integriranja.

1.2 Gaussovski proces IN NJEGOVO ODVOD

Definicija 1.2 (ponovitev, glej [integral-matching.md](#) §1.2). $\hat{x}$ je GP z jedrom $k(t, t')$; posteriorna povprečna funkcija je $\hat{x}(t) = k(t)^\top (K + \sigma^2 I)^{-1} y$.

Definicija 1.2' (odvod GP-ja). Če je $f \sim \mathcal{GP}(\mu, k)$ in je k dvakrat odvedljiv, je f' prav tako Gaussovski proces (GP je zaprt pod linearnimi operatorji - odvajanje je linearno), s

$$\text{Cov}[f'(t), f'(t')] = \frac{\partial^2 k(t, t')}{\partial t \partial t'}, \quad \text{Cov}[f'(t), f(t')] = \frac{\partial k(t, t')}{\partial t}. \quad (1.1)$$

Posteriorna povprečna funkcija in varianca ODVODA (pogojeno na $y_i = f(t_i) + \eta_i$) sta

$$\hat{x}'(t^*) = k'_*(t^*)^\top (K + \sigma^2 I)^{-1} y, \quad \text{Var}_{\text{post}}[\hat{x}'(t^*)] = k''(t^*, t^*) - k'_*(t^*)^\top (K + \sigma^2 I)^{-1} k'_*(t^*) \quad (1.2)$$

kjer je $k'_*(t)_i := \partial k(t, t_i) / \partial t$. To je natanko `_kernel_deriv_wrt_first` (posteriorno povprečje) in `_FittedGP.var_deriv` (posteriorna varianca) v `pybm/estimate/gradient_matching.py` - obe formuli v kodi realizirani prek shranjenega Choleskyjevega faktorja L ($K + \sigma^2 I = LL^\top$), z $v(t) := L^{-1}k(t)$, tako da je $k(t)^\top (K + \sigma^2 I)^{-1} k(t') = v(t)^\top v(t')$ - ista konstrukcija kot pri `_FittedGP.var`.

Vir: E. Solak, R. Murray-Smith, W. E. Leithead, D. J. Leith, C. E. Rasmussen, *Derivative observations in Gaussian process models of dynamic systems*, NeurIPS 16, 2003 - izvorna izpeljava (1.1)-(1.2) za GP-je z odvodnimi opazovanji/poizvedbami. C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006, §9.4 - ista formula, standardni učbeniški zapis.

1.3 Lipschitzova zveznost

Enaka Definicija 1.3 kot v `integral-matching.md` §1.3: F je L_x -Lipschitzova v x in L_c -Lipschitzova v c . Spet edino, kar potrebujemo o F samem.

1.4 Enakomerna napaka interpolacije IN NJENEGA ODVODA

Definicija 1.4 (ponovitev). $e(t) := \hat{x}(t) - x(t)$, $\sup_t \|e(t)\| \leq \varepsilon$ z visoko verjetnostjo (glej `integral-matching.md` §1.4 za vir - posteriorna kontrakcija GP regresije).

Definicija 1.4' (NOVO). Naj bo $e'(t) := \hat{x}'(t) - x'(t)$ napaka ODVODNE ocene (x' je odvod prave, deterministične rešitve - ne slučajna spremenljivka; ves šum je v $\hat{x}'$). Predpostavimo $\varepsilon' > 0$, tako da z visoko verjetnostjo

$$\sup_t \|e'(t)\| \leq \varepsilon'. \quad (1.3)$$

ε' je - tako kot ε - eksogen v tem dokumentu; §1.5 spodaj izpelje natančno razmerje med ε' in ε , ki je JEDRO tega celotnega dokumenta.

1.5 Razmerje ε' proti ε : zakaj odvajanje ojači šum

To je natančna, ne le hevristična izpeljava trditve, ki je bila v `integral-matching.md` §6.3 podana kot dimenzijski argument.

Trditev 1.5 (apriorno razmerje za stacionarno jedro). Za stacionarno jedro $k(t, t') = \sigma_f^2 \rho((t - t')/\ell)$ z gladkim, sodim ρ , $\rho(0) = 1$, je apriorna varianca funkcije $\text{Var}[f(t)] = k(t, t) = \sigma_f^2$, apriorna varianca odvoda pa (iz (1.1) pri $t = t'$, uporabljeno na kvadratno eksponentno jedro (1.2) iz `integral-matching.md`)

$$\text{Var}[f'(t)] = \frac{\partial^2 k(t, t')}{\partial t \partial t'} \Big|_{t=t'} = \frac{\sigma_f^2}{\ell^2}. \quad (1.4)$$

Izpeljava za RBF jedro $k(t, t') = \sigma_f^2 \exp(-(t - t')^2/(2\ell^2))$:

$$\frac{\partial k}{\partial t} = -\sigma_f^2 \frac{t - t'}{\ell^2} \exp\left(-\frac{(t - t')^2}{2\ell^2}\right), \quad \frac{\partial^2 k}{\partial t \partial t'} = \frac{\sigma_f^2}{\ell^2} \exp\left(-\frac{(t - t')^2}{2\ell^2}\right) \left[1 - \frac{(t - t')^2}{\ell^2}\right].$$

Pri $t = t'$ oklepaj postane 1, kar da natanko (1.4). ■

Posledica (razmerje standardnih deviacij).

$$\boxed{\text{std}[f'(t)] = \frac{\text{std}[f(t)]}{\ell}} \quad (1.5)$$

Od apriorne k posteriorni trditvi (previdnost). (1.4)-(1.5) sta EKSAKTNI za apriorno (brez podatkov) porazdelitev. Za POSTERIORNO varianco (1.2), ki jo dejansko uporabljamo (`.var`, `.var_deriv` v kodi), enako razmerje ni algebrsko eksaktno - oba, $\text{Var}_{\text{post}}[\hat{x}(t)]$ in $\text{Var}_{\text{post}}[\hat{x}'(t)]$, se zmanjšata glede na podatke, a NE nujno za isti faktor. Empirično (glej `pybm.benchmark.benchmark_2`, GP na Bled `phyto.conc`) razmerje ostane blizu $1/\ell$, kadar je gostota podatkov glede na ℓ približno enakomerna - to je razlog, da v `integral-matching.md` §6.3 ta trditev nastopi kot "dimenzijska ocena", ne strog izrek. V tem dokumentu je (1.4)-(1.5) POTRJENA kot eksakten rezultat na apriorni ravni - kar je dovolj močna osnova za vso nadaljnjo analizo, ker gradient matching implicitno primerja ε' (odvod) in ε (vrednost) na ISTI podatkovni gostoti, kjer aproksimacija $\varepsilon' \approx \varepsilon/\ell$ najboljše drži.

Zakaj to pomeni "bolj občutljiv na šum". ε je raven šuma v $\hat{x}$ sami; $\varepsilon' = \varepsilon/\ell$ je raven šuma v $\hat{x}'$. Ker je ℓ tipično MANJŠI od 1 v enotah, v katerih so podatki naravno merjeni (lengthscale je "kako hitro se stvari spreminjajo", ne absolutna skala), je $1/\ell$ tipično FAKTOR OJAČITVE, ne dušenja. Gradient matching primerja F neposredno s to ojačano količino ($\hat{x}'$) - integral matching pa NIKOLI ne rabi $\hat{x}'$ sploh (glej §6 spodaj).

2. Metoda gradient matching

2.1 Definicija izgube

Definicija 2.1. Za dano množico kolokacijskih točk $t_1, \dots, t_m$ (lahko, a ni nujno, enaka mreži podatkov - v kodi `collocation_times`, privzeto `t_eval`) in kandidatni parameter c definiramo

$$r_i(c) := \hat{x}'(t_i) - F(\hat{x}(t_i), t_i, c), \quad i = 1, \dots, m, \quad (2.1)$$

in $J(c) = \sum_i \|r_i(c)\|^2$. Ocena je $\hat{c} = \arg \min_c J(c)$.

V primerjavi z integral matchingom (2.1) (glej `integral-matching.md`) tu NI integrala: vsaka r_i je TOČKOVNA, neodvisna preveritev, ali $\hat{x}$ lokalno reši ODE v odvodni (močni) obliki.

2.2 Razčlenitev $r_i(c)$

Ker x reši ODE pri c_0 : $x'(t) = F(x(t), t, c_0)$. Ker je x deterministična funkcija (ves šum je v $\hat{x}$), je $e'(t) = \hat{x}'(t) - x'(t)$ dobro definiran (Definicija 1.4'), torej

$$\hat{x}'(t_i) = x'(t_i) + e'(t_i) = F(x(t_i), t_i, c_0) + e'(t_i). \quad (2.2)$$

Vstavimo v (2.1):

$$r_i(c) = e'(t_i) + [F(x(t_i), t_i, c_0) - F(\hat{x}(t_i), t_i, c)]. \quad (2.3)$$

Znotraj oglatega oklepaja prištejemo in odštejemo $F(\hat{x}(t_i), t_i, c_0)$ (enaka Lipschitzova razčlenitev kot `integral-matching.md` (3.1)):

$$F(x, t_i, c_0) - F(\hat{x}, t_i, c) = \underbrace{[F(x, t_i, c_0) - F(\hat{x}, t_i, c_0)]}_{\leq L_x \|e(t_i)\|} + \underbrace{[F(\hat{x}, t_i, c_0) - F(\hat{x}, t_i, c)]}_{\text{signal o } c-c_0}. \quad (2.4)$$

$$r_i(c) = \underbrace{e'(t_i)}_{\text{odvodni šum, red } \varepsilon/\ell} + \underbrace{[F(x(t_i), t_i, c_0) - F(\hat{x}(t_i), t_i, c_0)]}_{\text{vrednostni šum, red } L_x \varepsilon} + \underbrace{[F(\hat{x}(t_i), t_i, c_0) - F(\hat{x}(t_i), t_i, \hat{c})]}_{\text{signal o } c}$$

Primerjava z integral matchingom (2.4). Strukturno enaka razčlenitev (šum + šum + signal), a z eno ključno razliko: integral matchingov "šumski" člen je $e(t_i) - e(t_{i-1})$ - razlika DVEH vrednostnih napak, ki lahko z Delta-jem (širino okna) postane poljubno majhna relativno na signal (glej [integral-matching.md](#) §5.1). Gradient matchingov prvi šumski člen $e'(t_i)$ je fiksiran na odvodno skalo ε/ℓ - NI načina, da bi ga s katerokoli izbiro kolokacijskih točk zmanjšali (edino zmanjšanje ε same, tj. boljši/gostejši podatki, pomaga - glej §4.4 spodaj). To je natančna matematična oblika "gradient matching je bolj občutljiv na šum".

3. Meja za izgubo pri c_0 in kriterij ustavitve

3.1 Groba (worst-case) meja

Z (1.3), (1.4)-Definicijo 1.4 in trikotniško neenakostjo iz (2.5) pri $c = c_0$ (zadnji člen odpade):

$$\|r_i(c_0)\| \leq \varepsilon' + L_x \varepsilon. \quad (3.1)$$

Seštejemo po $i = 1, \dots, m$:

$$\|r(c_0)\|_1 = \sum_{i=1}^m \|r_i(c_0)\| \leq m(\varepsilon' + L_x \varepsilon) \quad (3.2)$$

Primerjava z integral matchingovo (3.3) ($\|l(c_0)\|_1 \leq 2n\varepsilon + L_x \varepsilon T$): tam je meja odvisna od ŠTEVILA OKEN n in RAZPONA T (prek Lipschitzovega člena); tu je odvisna od ŠTEVILA KOLOKACIJSKIH TOČK m in - prek $\varepsilon' = \varepsilon/\ell$ - od GP-jeve lengthscale same, ne od razpona podatkov. Uporabimo (1.5):

$$\|r(c_0)\|_1 \lesssim m\varepsilon \left(\frac{1}{\ell} + L_x \right). \quad (3.3)$$

Kdaj prevlada odvodni šum. Člen $1/\ell$ prevlada nad L_x , kadar je $\ell < 1/L_x$ - tj. kadar GP-jeva korelacijska dolžina ni veliko večja od karakteristične časovne skale dinamike same ($1/L_x$ ima enote časa, ker je L_x definiran prek $\|F(x) - F(x')\| \leq L_x \|x - x'\|$, torej groba "časovna konstanta" sistema). To je tipičen režim na realnih, ne pretirano gladko vzorčenih podatkih (glej §7) - v tem režimu je (3.3) DOMINIRANA z odvodnim šumom, ne z modelovo lastno občutljivostjo L_x : **nizka $J(c_0)$ meja gradient matchinga je v praksi skoraj v celoti posledica ε/ℓ , ne prave informacije o dinamiki.**

3.2 Zakaj je (3.2) preohlapna

Enak argument kot [integral-matching.md](#) §3.2: vsota m absolutnih vrednosti prek trikotniške neenakosti je pesimistična, če so $e'(t_i)$ približno neodvisne (kar velja za t_i narazen za $\gg \ell$ - glej §4.4 spodaj) slučajne spremenljivke s povprečjem nič. Koncentracijske neenakosti (Bernstein) dajo za $J(c_0) = \sum_i \|r_i(c_0)\|^2$ mejo reda $O(m\varepsilon'^2) = O(m\varepsilon^2/\ell^2)$ z nihanji $O(\sqrt{m}\varepsilon^2/\ell^2)$ - ostrejša od naivne $O(m^2\varepsilon^2/\ell^2)$.

Vir: enak kot [integral-matching.md](#) §3.2 - S. Boucheron, G. Lugosi, P. Massart, *Concentration Inequalities*, Oxford University Press, 2013.

3.3 Praktičen kriterij ustavitve

Enak parametrični-bootstrap pristop kot `integral-matching.md` §3.3, tu neposredno prenosljiv: iz GP posteriorja (za $\hat{x}'$, ne $\hat{x}$) vzorčimo realizacije, prerašunamo J pri trenutnem $\hat{c}$, dobimo empirično ničelno porazdelitev $J(c_0)$. Ni (še) implementirano v `pybm.estimate.gradient_matching` (glej §7, praktična priporočila).

Vir: J. O. Ramsay, G. Hooker, D. Campbell, J. Cao, *Parameter estimation for differential equations: a generalized smoothing approach*, JRSS-B 69(5), 2007, 741-796.

4. Identifikabilnost

4.1-4.2 Fisherjeva informacija in Gauss-Newton linearizacija

Enaka konstrukcija kot `integral-matching.md` §4.1-4.2, s pointwise (ne integrirano) matriko občutljivosti:

$$S_i^{GM} := \frac{\partial F}{\partial c}(\hat{x}(t_i), t_i, c_0) \in \mathbb{R}^{d \times p}, \quad G^{GM} := \sum_{i=1}^m (S_i^{GM})^\top S_i^{GM}. \quad (4.1)$$

Primerjaj z integral matchingovim $S_i^{IM} = \int_{t_{i-1}}^{t_i} \partial F / \partial c d\tau$ (`integral-matching.md` (4.1)) - INTEGRIRANA, ne pointwise, občutljivost.

Ista asimptotska teorija (Seber & Wild, pogl. 5) da $\hat{c} \approx \mathcal{N}(c_0, \sigma^2(G^{GM})^{-1})$, isti radij nerazločljivosti $|\hat{c} - c_0|_v \sim \sqrt{\text{raven šuma} / \lambda}$ za lastni vektor v matrike G^{GM} z lastno vrednostjo λ (`integral-matching.md` Eq. 4.4).

`pybm.estimate.gradient_matching._identifiability_report` izračuna to natanko - iz `least_squares_result.jac` (že izračunan Jacobijan pri konvergenci) prek SVD, $G^{GM} = J_r^\top J_r$ z lastnimi vrednostmi = kvadrati singularnih vrednosti J_r . Enaka implementacija se uporablja za `IntegralMatchingResult.identifiability_report()` - ista funkcija, različen J_r na vhodu.

4.3 Strukturna vs. praktična identifikabilnost

Enaka razlika kot `integral-matching.md` §4.4 - strukturna (iz brezšumnih, popolnih podatkov) proti praktični (iz danih, končnih, zašumljenih podatkov, torej odvisna od G).

4.4 Zakaj je G^{GM} tipično slabše pogojena kot G^{IM} (hevristični argument)

(Ta trditev je bila v `integral-matching.md` §4.4 zapisana kot posledica brez izpeljave - tukaj podana natančneje, a še vedno kot kvalitativen, ne strog argument.)

Integracija je LINEARNA GLAJENJA/POVPREČENJA operacija: S_i^{IM} je (do faktorja širine okna) POVPREČJE $\partial F / \partial c$ prek mnogih bližnjih τ znotraj okna, medtem ko je S_i^{GM} ovrednoten v ENI SAMI točki t_i . Povprečenje teži k temu, da "zapolni" smeri v parametrskega prostoru, ki so ob KATERIKOLI POSAMEZNI točki šibko vzbujene, a se kumulativno prek okna seštejejo v znaten prispevek - podoben pojav kot pri numeričnem računanju ranga: vsota (integral) matrik ima praviloma manj/manjše ničelne singularne vrednosti kot posamezna matrika sama. To NI dokazana neenakost za splošen F , je pa skladno z empiričnim opažanjem na Bled podatkih (`pybm.benchmark.benchmark_2`): G^{GM} -jev `identifiability_report()` je v praksi našel več in bolj degenerirane (`relative_scale`) smeri kot ustrezen G^{IM} na isti strukturi.

4.5 Gostota kolokacijskih točk relativno na ℓ

Direktna posledica GP-jeve korelacijske strukture (Definicija 1.2): za $|t_i - t_j| \ll \ell$ sta $\hat{x}(t_i)$ in $\hat{x}(t_j)$ (in posledično implicirana S_i^{GM}, S_j^{GM}) skoraj isti naključni spremenljivki pod GP posteriorjem - dodajanje kolokacijskih točk gosteje kot ℓ NE doda novih neodvisnih omejitev v G^{GM} , enako kot `integral-matching.md` §5.4 ugotovi za okna ožja od ℓ pri integral matchingu. To je gradient matchingov analog tistega vodila: **razmik kolokacijskih točk naj bo reda ℓ** , ne gostejši - gostejša mreža poveča m (in navidezno G^{GM}), a brez prave dodatne informacije, poveča pa računski strošek in tveganje numerične skoraj-singularnosti G^{GM} (skoraj-podvojeni stolpci/vrstice).

`pybm.estimate.integral_matching._auto_stride` to že implementira za integral matching (izbira `stride` iz GP-jeve `lengthscale`); enakovredna "auto" izbira razmika kolokacijskih točk za gradient matching (danes `collocation_times` privzeto kar `t_eval`, brez posebne obravnave glede na ℓ) še ni implementirana - glej §7.

5. Overfitting pri redkih, lokalnih preveritvah

To je bil izvoren motiv za razvoj integral matchinga (glej `pybm.estimate.integral_matching`-jev modulski docstring, točka 2), tu formaliziran.

Trditev (kvalitativna). Gradient matching preveri, ali $\hat{x}$ lokalno reši ODE, na m IZOLIRANIH točkah. Če ima model p prostih parametrov s p primerljiv ali večji od ŠTEVILA UČINKOVITO NEODVISNIH omejitev $m_{\text{eff}} \sim (\text{razpon podatkov})/\ell$ (ne surovega m - glej §4.5), je sistem $\{r_i(c) = 0\}_{i=1}^m$ podpoločen v smislu, da obstaja $c \neq c_0$ z majhnim (ali celo ≈ 0) $J(c)$, ki NE reproducira prave trajektorije MED kolokacijskimi točkami - F z dovolj svobode se lahko "prilagodi" vsaki izolirani zahtevi posebej, brez globalne konsistentnosti, ki bi jo prava integracija/simulacija zahtevala.

To je NATANKO opažanje na realnem Bled modelu (glej `pybm.benchmark.benchmark_2`-jev modulski docstring): majhen gradient-matching rezidual, a naprej-simulirana trajektorija, ki močno odstopa od podatkov. Formalno je to isti pojav kot majhna lastna vrednost v G^{GM} (§4) - "podpoločenost" in "overfitting" sta tu dva jezika za isto stvar: obstaja smer v prostoru parametrov, vzdolž katere $J(c)$ skoraj ne raste, torej optimizator lahko po tej smeri poljubno "zdrsne" stran od c_0 brez kazni v svoji lastni (točkovni) izgubi.

Zakaj integral matching to omili (ne odpravi). Integracija prek okna zahteva, da F pri danem c pravilno napove AKUMULIRANO spremembo prek celotnega okna, kar je strožja, manj lokalna zahteva kot ujemanje v eni sami točki - manj "prostora" za F , da se prilagodi izolirani zahtevi brez globalne konsistentnosti. To NE odpravi podpoločenosti nasploh (glej `integral-matching.md` §5.2 - Grönwallova pristranskost pri zelo širokih oknih uvede svoj lasten problem), je pa strožja preveritev za PRIMERLJIVO število prostih parametrov.

6. Primerjava z integral matchingom

6.1 Viri za gradient matching kot metodo

Vir: J. O. Ramsay et al. (2007), kot v §3.3; B. Calderhead, M. Girolami, N. D. Lawrence, *Accelerating Bayesian inference over nonlinear differential equations with Gaussian processes*, NeurIPS 21, 2008 - GP-based gradient matching kot Bayesovska metoda; P. Wenk, A. Gotovos, S. Bauer, N. S. Gorbach, A. Krause, J. M. Buhmann, *Fast Gaussian Process Based Gradient Matching for Parameter Identification in Systems of Nonlinear ODEs*, AISTATS 2019 - hitra (ne-Bayesovska, point-estimate) različica, najbližja implementaciji v `pybm.estimate.gradient_matching`.

6.2 Dobro in slabo postavljeni problemi (ponovitev)

Enaka Definicija 6.2 (Hadamard) kot [integral-matching.md](#) §6.2. Numerično ODVAJANJE zašumljenih podatkov je slabo postavljen problem (majhen šum $\rightarrow$ poljubno velika sprememba odvoda); INTEGRACIJA je nasprotno kompakten (gladilen) operator, dobro postavljen. Gradient matching stoji na napačni (slabo postavljeni) strani te delitve - integral matching na pravilni.

Vir: H. W. Engl, M. Hanke, A. Neubauer, *Regularization of Inverse Problems*, Kluwer, 1996, pogl. 2.

6.3 Limita $\ell \rightarrow 0$ oz. $\Delta \rightarrow 0$: ista stvar z dveh strani

[integral-matching.md](#) §6.4 pokaže, da integral matching zvezno degenerira v gradient matching, ko $\Delta \rightarrow 0$ (Taylor/MVT: $l_i(c) \approx \Delta_i \cdot r_i^{GM}(c)$). Ta dokument doda drugo polovico slike: gradient matching SAM nima analogne "širine" parametra, ki bi ga lahko poljubno povečeval - edini prosti "gumb" na strani gradient matchinga je GOSTOTA/RAZPORED kolokacijskih točk (m , §4.5), ne kaka Δ . To je STRUKTURNA asimetrija med metodama, ne le tehnična: integral matching ima en dodaten prost parameter (Δ/stride), ki gradient matchingu manjka - in prav ta parameter je tisti, ki v [integral-matching.md](#) §5 omogoči nadzor nad kompromisom šum/pristranskost. Gradient matching tega kompromisa preprosto nima na voljo; njegov edini vzvod (§4.5, gostota točk) vpliva na G (identifikabilnost), NE na ε' samo (šumni pod, glej §1.5 - ε' je odvisen od ℓ in kvalitete podatkov, ne od tega, KOLIKO kolokacijskih točk postavimo).

6.4 Primerjalna tabela

Lastnost	Gradient matching	Integral matching ($\Delta \gtrsim \ell$)
Operacija na $\hat{x}$	odvajanje (ill-posed)	integracija (well-posed, gladil)
Šumni pod na enoto	$O(\varepsilon/\ell)$ na TOČKO	$O(\varepsilon)$ na OKNO, neodvisno od ℓ
Prost parameter za kompromis šum/pristranskost	noben (§6.3)	Δ (stride)
Občutljivostna matrika S_i	pointwise, $\partial F / \partial c$ v t_i	integrirana, $\int \partial F / \partial c d\tau$
Tipična pogojenost G	slabša (§4.4, hevrstika)	boljša (§4.4, hevrstika)
Tveganje	overfitting na izolirane točke (§5)	Grönwallova pristranskost pri širokih oknih
Degenerira v	integral matching, ko $\Delta \rightarrow 0$	gradient matching, ko $\Delta \rightarrow 0$

Odgovor na "zakaj smo bolj občutljivi na šum kot pri integriranju": formalno, ker gradient matching primerja F neposredno z $\hat{x}'$, katerega lastni šum $\varepsilon' \approx \varepsilon/\ell$ JE STRUKTURNO OJAČEN glede na ε (Trditev 1.5, eksaktna na apriorni ravni) - integral matching pa NIKOLI ne rabi $\hat{x}'$, njegov levi del residuala ($\hat{x}(t_{i+1}) - \hat{x}(t_i)$) je eksakten prek fundamentalnega izreka in nosi šum reda ε SAM (ne ε/ℓ), dodatno zmanjšljiv s širino okna ([integral-matching.md](#) Eq. 5.2). To ni le empirično opažanje - je neposredna posledica tega, da je odvajanje slabo, integracija pa dobro postavljena operacija na zašumljenih podatkih (§6.2).

7. Povzetek in praktična priporočila

1. **Šumni pod** (§1.5, §3): $\varepsilon' \approx \varepsilon/\ell$ je STRUKTURNA, ne odpravljiva lastnost gradient matchinga - noben izbor kolokacijskih točk je ne zmanjša. Edino boljši podatki (manjši ε , torej gostejši/manj zašumljeni observations, ki jih GP fita) pomagajo.
2. **Identifikabilnost** (§4): izračunaj $G^{GM} = \sum_i (S_i^{GM})^\top S_i^{GM}$ (že implementirano: `GradientMatchingResult.identifiability_report()`); pričakuj slabšo pogojenost kot pri integral matchingu na isti strukturi (§4.4, heuristika - preveri direktno na svojih podatkih, ne predpostavljaj).
3. **Gostota kolokacijskih točk** (§4.5): reda ℓ , ne gostejše - gostejša mreža ne doda prave informacije, poveča pa računski strošek in numerično skoraj-singularnost G^{GM} . `_auto_stride` (integral matching) obstaja; enakovredna avtomatska izbira za gradient matching NI (še) implementirana - naraven kandidat za prihodnje delo, glej `_FittedGP.lengthscale` (že izračunan, samo ni uporabljen za to na strani gradient matchinga).
4. **Overfitting na izolirane točke** (§5): majhen $J(\hat{c})$ NE zagotavlja, da $\hat{c} \approx c_0$ ali da fitani model reproducira pravo trajektorijo MED kolokacijskimi točkami - preveri z resnično naprej-simulirano trajektorijo (`_singleshooting_loss/_test_mse`), ne zaupaj $J(\hat{c})$ sami.
5. **Uteževanje po GP-jevi negotovosti** (`weight_by_uncertainty=True`, glej `_FittedGP.var_deriv`): implementirano in matematično korektno (uteži nižje kolokacijske točke, kjer je $\text{Var}[\hat{x}'(t)]$ velika), a EMPIRIČNO na Bled podatkih dalo mešane rezultate (enkrat bolje, enkrat slabše - preverjeno direktno, glej chat log 2026-08-26) - privzeto izklopljeno, ni dokazana izboljšava.
6. **Praktičen kriterij ustavitve** (§3.3): bootstrap iz GP posteriorja - opisan v teoriji, NI (še) implementiran v `pybm.estimate.gradient_matching`.

Literatura

Deljena z `integral-matching.md` (isti viri za GP regresijo, RKHS, Lipschitz, Grönwall, identifikabilnost, Hadamard, regularizacijo inverznih problemov - glej tam za polni seznam). Novi viri, specifični za ta dokument:

1. E. Solak, R. Murray-Smith, W. E. Leithead, D. J. Leith, C. E. Rasmussen. "Derivative observations in Gaussian process models of dynamic systems." *NeurIPS* 16, 2003.
2. B. Calderhead, M. Girolami, N. D. Lawrence. "Accelerating Bayesian inference over nonlinear differential equations with Gaussian processes." *NeurIPS* 21, 2008.
3. P. Wenk, A. Gotovos, S. Bauer, N. S. Gorbach, A. Krause, J. M. Buhmann. "Fast Gaussian Process Based Gradient Matching for Parameter Identification in Systems of Nonlinear ODEs." *AISTATS*, 2019.
4. C. E. Rasmussen, C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006, §9.4 (odvodi GP-jev).