

Integral matching: matematične osnove

Analiza napake, identifikabilnosti in primerjava z gradient matchingom pri ocenjevanju parametrov ODE iz zašumljenih podatkov.

Kako brati ta učbenik

Vsako poglavje uvede en ali dva nova pojma, ju formalno definira, poda vir za nadaljnje branje, nato pa pojem takoj uporabi v izpeljavi. Izpeljave so zapisane po korakih — brez preskokov. Kjer trditev ni strogo dokazana, ampak je hevristični (dimenzijski) argument, je to eksplicitno označeno.

Notacija je fiksna skozi cel dokument:

- $x(t) \in \mathbb{R}^d$ — prava (neznana) rešitev ODE,
- $c \in \mathbb{R}^p$ — vektor parametrov, c_0 njegova prava vrednost,
- $F : \mathbb{R}^d \times \mathbb{R} \times \mathbb{R}^p \rightarrow \mathbb{R}^d$ — desna stran enačbe, $x' = F(x, t, c)$,
- $y_i = x(t_i) + \eta_i$, $\eta_i \sim \text{šum}$ — opazovani podatki,
- $\hat{x}(t)$ — interpolant (GP posteriorna povprečna funkcija), ocenjen iz $\{(t_i, y_i)\}$,
- $t_0 < t_1 < \dots < t_n$ — mreža časov, $\Delta_i = t_i - t_{i-1}$, $T = t_n - t_0$.

1. Gradniki

1.1 Problem ocenjevanja parametrov ODE

Definicija 1.1. Dana je družina ODE $x' = F(x, t, c)$, $c \in \Theta \subset \mathbb{R}^p$, in zašumljena opazovanja $y_i = x(t_i) + \eta_i$ prave rešitve $x(\cdot)$, ki reši sistem pri neznanem $c = c_0$. Cilj je oceniti c_0 iz $\{y_i\}$.

To je poseben primer *inverznega problema* — iščemo vzrok (parameter) iz posledice (zašumljena opazovanja), kar je po definiciji Hadamarda težje kot direkten problem, ker rešitev ni nujno zvezno odvisna od podatkov.

Vir: J. Hadamard, *Sur les problèmes aux dérivées partielles et leur signification physique*, Princeton University Bulletin 13 (1902), 49–52 — izvor pojma dobro/slabo postavljenega problema (uporabimo ga v poglavju 6).

1.2 Gaussovski proces kot interpolant

Definicija 1.2 (Gaussovski proces). $\hat{x}$ je Gaussovski proces (GP), če je za vsak končen nabor točk $t_1, \dots, t_m$ vektor $(\hat{x}(t_1), \dots, \hat{x}(t_m))$ skupno normalno porazdeljen. GP je določen s povprečno funkcijo $\mu(t)$ in kovariančnim jedrom $k(t, t')$.

Pri regresiji z opazovanji $y_i = x(t_i) + \eta_i$, $\eta_i \sim \mathcal{N}(0, \sigma^2)$ neodvisno, je posteriorna povprečna funkcija (ki jo vzamemo za interpolant $\hat{x}$) enaka

$$\hat{x}(t) = k(t)^\top (K + \sigma^2 I)^{-1} y, \quad K_{ij} = k(t_i, t_j), \quad k(t)_i = k(t, t_i). \quad (1.1)$$

Za stacionarno jedro (npr. kvadratno eksponentno, squared-exponential)

$$k(t, t') = \sigma_f^2 \exp\left(-\frac{(t - t')^2}{2\ell^2}\right) \quad (1.2)$$

parameter ℓ imenujemo **korelacijska dolžina (lengthscale)** — razdalja, na kateri jedro pade na $\sim e^{-1/2}$ svoje vrednosti; to je "karakteristična skala gladkosti" funkcije, ki jo GP modelira. Ta ℓ bo ključna v poglavju 5.

Vir: C. E. Rasmussen, C. K. I. Williams, *Gaussian Processes for Machine Learning*, MIT Press, 2006 — poglavje 2 za regresijsko formulo (1.1), poglavje 4.2 za lengthscale in stacionarna jedra.

1.3 Lipschitzova zveznost

Definicija 1.3. Funkcija F je L_x -Lipschitzova v x (enakomerno v t, c), če

$$\|F(x, t, c) - F(x', t, c)\| \leq L_x \|x - x'\| \quad \forall x, x', t, c. \quad (1.3)$$

Analogno definiramo L_c -Lipschitzovost v c . Ta pogoj je standarden pogoj za eksistenco in enoličnost rešitve ODE (Picard–Lindelöf) in bo v naslednjih poglavjih edino, kar potrebujemo o F , da lahko kontroliramo, kako se napaka v $\hat{x}$ prenese v napako v c .

Vir: W. Rudin, *Principles of Mathematical Analysis*, 3. izd., McGraw-Hill, 1976, §9 — definicija; E. A. Coddington, N. Levinson, *Theory of Ordinary Differential Equations*, McGraw-Hill, 1955, pogl. 1 — vloga Lipschitzovosti pri ODE.

1.4 Enakomerna napaka interpolacije

Definicija 1.4. Naj bo $e(t) := \hat{x}(t) - x(t)$ napaka interpolanta. Predpostavimo, da obstaja $\varepsilon > 0$, tako da z visoko verjetnostjo

$$\sup_t \|e(t)\| \leq \varepsilon. \quad (1.4)$$

Konstanto ε v tem dokumentu jemljemo kot **dano** (eksogeno) — v praksi jo dobimo bodisi iz širine GP-jevega kredibilnega pasu (posteriorna standardna deviacija $\times$ kvantil), bodisi iz teoretičnih rezultatov o **posteriorni kontrakciji** GP regresije, ki povedo, s kakšno hitrostjo $\varepsilon \rightarrow 0$, ko število podatkov $\rightarrow \infty$, glede na gladkost prave funkcije in izbiro jedra.

Vir: A. W. van der Vaart, J. H. van Zanten, *Rates of contraction of posterior distributions based on Gaussian process priors*, Annals of Statistics 36(3), 2008, 1435–1463.

1.5 RKHS in odvod GP

Interpolant $\hat{x}$ ni le zvezen, ampak (za gladka jedra kot (1.2)) neskončnokrat odvedljiv, in obstaja natančna povezava med gladkostjo funkcije v pripadajočem **reproducirajočem jedrnem Hilbertovem prostoru (RKHS)** in tem, kako se napaka ε ojači pri odvajanju. To bomo potrebovali v poglavju 6; za zdaj samo definicija.

Definicija 1.5. RKHS $\mathcal{H}_k$, pridružen jedru k , je Hilbertov prostor funkcij, v katerem velja *reproducing property* $f(t) = \langle f, k(\cdot, t) \rangle_{\mathcal{H}_k}$. Norma $\|f\|_{\mathcal{H}_k}$ meri "gladkost" funkcije glede na k .

Vir: G. Wahba, *Spline Models for Observational Data*, SIAM, 1990, pogl. 1 — RKHS; Rasmussen & Williams (2006), pogl. 9.4 — odvodi GP in njihova (ko)varianca.

2. Metoda integral matching

2.1 Definicija izgube

Definicija 2.1 (Integral matching loss). Za dano mrežo $t_0 < \dots < t_n$ in kandidatni parameter c definiramo residue

$$l_i(c) := \hat{x}(t_i) - \hat{x}(t_{i-1}) - \int_{t_{i-1}}^{t_i} F(\hat{x}(\tau), \tau, c) d\tau, \quad i = 1, \dots, n, \quad (2.1)$$

in skupno izgubo $l(c) = \sum_i \|l_i(c)\|$ (ali $J(c) = \sum_i \|l_i(c)\|^2$ za gladko optimizacijo). Ocena parametra je $\hat{c} = \arg \min_c J(c)$.

Intuitivno: (2.1) preverja, ali interpolant *lokalno reši* ODE v integralski (šibki) obliki na vsakem podintervalu — namesto da bi zahtevali $\hat{x}'(t) \approx F(\hat{x}, t, c)$ v vsaki točki (to je *gradient matching*, poglavje 6), zahtevamo ujemanje po *integriranem* prirastku.

2.2 Proces napake $e(t)$

Ker x reši ODE pri c_0 , velja $x(t) = x(t_0) + \int_{t_0}^t F(x(\tau), \tau, c_0) d\tau$. Po definiciji $e(t) = \hat{x}(t) - x(t)$ torej

$$e(t) = \hat{x}(t) - x(t_0) - \int_{t_0}^t F(x(\tau), \tau, c_0) d\tau. \quad (2.2)$$

Iz (2.2), za dva zaporedna časa:

$$e(t_i) - e(t_{i-1}) = [\hat{x}(t_i) - \hat{x}(t_{i-1})] - \int_{t_{i-1}}^{t_i} F(x(\tau), \tau, c_0) d\tau. \quad (2.3)$$

2.3 Razčlenitev $l_i(c)$

Iz (2.3) izrazimo $\hat{x}(t_i) - \hat{x}(t_{i-1}) = e(t_i) - e(t_{i-1}) + \int_{t_{i-1}}^{t_i} F(x, \tau, c_0) d\tau$ in vstavimo v (2.1):

$$l_i(c) = \underbrace{e(t_i) - e(t_{i-1})}_{\text{interpolacijski šum}} + \underbrace{\int_{t_{i-1}}^{t_i} [F(x(\tau), \tau, c_0) - F(\hat{x}(\tau), \tau, c)] d\tau}_{\text{signal o } c} \quad (2.4)$$

To je ključna formula tega dokumenta: pove, da je vsak residual vsota (a) šuma, ki izvira izključno iz napake interpolanta, in (b) člena, ki nosi informacijo o razliki $c - c_0$. Vsa naslednja poglavja so posledice te enačbe.

3. Meja za izgubo pri c_0 in kriterij ustavitve

3.1 Groba (worst-case) meja

Znotraj integrala v (2.4) prištejemo in odštejemo $F(\hat{x}, \tau, c_0)$:

$$F(x, \tau, c_0) - F(\hat{x}, \tau, c) = \underbrace{[F(x, \tau, c_0) - F(\hat{x}, \tau, c_0)]}_{\leq L_x \|e(\tau)\| \text{ po (1.3)}} + \underbrace{[F(\hat{x}, \tau, c_0) - F(\hat{x}, \tau, c)]}_{\leq L_c \|c - c_0\|}. \quad (3.1)$$

Z (1.4) in trikotniško neenakostjo iz (2.4) in (3.1):

$$\|l_i(c)\| \leq 2\varepsilon + L_x \varepsilon \Delta_i + L_c \Delta_i \|c - c_0\|. \quad (3.2)$$

Pri $c = c_0$ zadnji člen odpade. Seštejemo po $i = 1, \dots, n$ (upoštevamo $\sum_i \Delta_i = T$):

$$\|l(c_0)\|_1 = \sum_{i=1}^n \|l_i(c_0)\| \leq 2n\varepsilon + L_x \varepsilon T \quad (3.3)$$

Interpretacija. Izguba pri *pravem* parametru ni nič — spodaj je omejena z ravno šuma $O(n\varepsilon)$. Optimizacija pod to mejo je fitanje šuma v interpolantu, ne iskanje boljšega c . To je naravni **kriterij ustavitve**.

3.2 Zakaj je (3.3) preohlapna

Meja (3.3) sešteva n absolutnih vrednosti prek trikotniške neenakosti, kar je pesimistično, če so $e(t_i) - e(t_{i-1})$ približno neodvisne naključne spremenljivke s povprečjem nič (kar velja, kadar je Δ_i velik v primerjavi z lengthscale ℓ — glej poglavje 5). V tem primeru za $J(c_0) = \sum_i \|l_i(c_0)\|^2$ **koncentracijske neenakosti** (npr. Bernsteinova) povedo, da $J(c_0)$ z visoko verjetnostjo leži blizu svoje pričakovane vrednosti $O(n\varepsilon^2)$, z nihanji reda $O(\sqrt{n}\varepsilon^2)$ — bistveno ostrejšje kot $O(n^2\varepsilon^2)$, ki bi ga dala naivna kvadrirana (3.3).

Vir: S. Boucheron, G. Lugosi, P. Massart, *Concentration Inequalities: A Nonasymptotic Theory of Independence*, Oxford University Press, 2013, pogl. 2 (Hoeffding) in pogl. 2.8 (Bernstein).

3.3 Praktičen kriterij ustavitve

Ker L_x redko poznamo natančno, analitična meja (3.3) v praksi služi le kot red velikosti. Bolj zanesljiv pristop je **parametrični bootstrap**: iz GP posteriorja vzorčimo realizacije šuma, preračunamo J pri trenutnem $\hat{c}$, in dobimo empirično ničelno porazdelitev $J(c_0)$. Ustavimo optimizacijo, ko $J(\hat{c})$ pade v to porazdelitev (analogno χ^2 -testu dobrega prileganja z $\approx nd$ prostostnimi stopnjami). To je natanko logika ustavitvenega kriterija v metodi *generalized profiling / parameter cascading*.

Vir: J. O. Ramsay, G. Hooker, D. Campbell, J. Cao, *Parameter estimation for differential equations: a generalized smoothing approach*, JRSS-B 69(5), 2007, 741–796 — §3–4 za kriterij ujemanja glajenja s podatki.

4. Identifikabilnost in radij nerazločljivosti

4.1 Fisherjeva informacijska matrika

Definicija 4.1. Za statistični model z gladko log-verjetjem je Fisherjeva informacijska matrika $I(c) = \mathbb{E}[\nabla_c \log p(y; c) \nabla_c \log p(y; c)^\top]$; njen inverz je (asimptotično) spodnja meja za kovarianco nepristranske cenilke (Cramér–Rao). Pri nelinearni regresiji z Gauss-Newtonovo aproksimacijo igra analogno vlogo matrika $J_r^\top J_r$, kjer je J_r jakobijan residualov.

Vir: G. A. F. Seber, C. J. Wild, *Nonlinear Regression*, Wiley, 2003, pogl. 2 (asimptotična teorija) in pogl. 12 (Fisherjeva informacija za ODE modele).

4.2 Gauss-Newton linearizacija in matrika G

Predpostavimo, da smo že blizu dna šuma ($J(c_0)$ majhen, poglavje 3), in lineariziramo $l_i(c)$ okoli c_0 z Definicijo 1.5-tipa odvodom $\partial F / \partial c$:

$$l_i(c) \approx l_i(c_0) - S_i(c - c_0), \quad S_i := \int_{t_{i-1}}^{t_i} \frac{\partial F}{\partial c}(\hat{x}(\tau), \tau, c_0) d\tau \in \mathbb{R}^{d \times p}. \quad (4.1)$$

S_i imenujemo **integrirana matrika občutljivosti** na i -tem intervalu. Kvadratna izguba se razvije kot

$$J(c) \approx J(c_0) - 2(c - c_0)^\top \sum_i S_i^\top l_i(c_0) + (c - c_0)^\top G (c - c_0), \quad \boxed{G := \sum_{i=1}^n S_i^\top S_i}. \quad (4.2)$$

G je tu natanko Gauss-Newtonov Hessian — analog Fisherjeve informacijske matrike za ta model.

4.3 Radij nerazločljivosti

Po standardni asimptotični teoriji nelinearnih najmanjših kvadratov (Seber & Wild, pogl. 5) je porazdelitev cenilke $\hat{c}$ približno

$$\hat{c} \approx \mathcal{N}(c_0, \sigma^2 G^{-1}), \quad (4.3)$$

kjer je σ^2 raven šuma na residual (reda ε^2 iz poglavja 3). Za lastni vektor v matrike G z lastno vrednostjo λ je torej standardna napaka ocene vzdolž v enaka $\sigma/\sqrt{\lambda}$:

$$\boxed{|\hat{c} - c_0|_v \sim \sqrt{\frac{\text{raven šuma}}{\lambda}}} \quad (4.4)$$

Interpretacija. Smeri s stroje/majhno λ (kombinacije parametrov, ki komaj vplivajo na integrirano dinamiko na tem oknu podatkov — npr. produkt dveh hitrostnih konstant, ko je viden le njun produkt) imajo velik radij nerazločljivosti: dva zelo različna c dasta praktično enak $\hat{x}$ in torej praktično enak loss. Smeri z velikim λ so ostro določene.

4.4 Strukturna vs. praktična identifikabilnost

Ta analiza spada v širše področje **identifikabilnosti** dinamičnih sistemov:

- *Strukturna identifikabilnost* — vprašanje, ali je c_0 enolično določen že iz **popolnih, brezšumnih** opazovanj (lastnost modela, ne podatkov).
- *Praktična identifikabilnost* — ali je c_0 enolično določljiv iz **danih, končnih in zašumljenih** podatkov (to je natanko vprašanje iz te sekcije; G je odvisen od mreže t_i in raznolikosti trajektorije).

Vir (strukturna): C. Cobelli, J. J. DiStefano, *Parameter and structural identifiability concepts and ambiguities*, American Journal of Physiology 239(1), 1980, R7–R24. **Vir (praktična, profile likelihood):** A. Raue et al., *Structural and practical identifiability analysis of partially observed dynamical models by exploiting the profile likelihood*, Bioinformatics 25(15), 2009, 1923–1929.

Pomembna posledica konstrukcije: ker G pri integral matchingu nastane z **integriranjem** občutljivosti prek celotnega podintervala (namesto vzorčenja v eni točki, kot pri gradient matchingu — glej poglavje 6), je G tipično bolj pogojena ($\lambda_{\min}$ večji) kot ustrezna matrika pri gradient matchingu, kar pomeni ožje intervale zaupanja za enako količino podatkov.

5. Vpliv dolžine intervala Δ

5.1 Dva režima glede na lengthscale

Groba meja $\|e(t_i) - e(t_{i-1})\| \leq 2\varepsilon$ iz (3.2) je realistična le, če sta t_i, t_{i-1} pod GP posteriorjem približno neodvisna, tj. $\Delta_i \gg \ell$ (Definicija 1.2). Ko je $\Delta_i \ll \ell$, je posteriorna povprečna funkcija na tej skali gladka (glej §1.5), zato je (hevrstično, iz Höllder/Lipschitzove zveznosti posteriornega povprečja z eksponento, ki jo določa ℓ):

$$\|e(t_i) - e(t_{i-1})\| \sim \varepsilon \cdot \frac{\Delta_i}{\ell} \quad (\Delta_i \ll \ell). \quad (5.1)$$

(Opomba: (5.1) je dimenzijski/hevrstični argument, ne strog izrek — natančna oblika je odvisna od izbire jedra; glej vir spodaj za rigorozne različice.)

Posledica za skupno mejo (3.3), odvisno od režima:

$$\|l(c_0)\|_1 \sim \begin{cases} 2n\varepsilon = \frac{2\varepsilon T}{\Delta} & \Delta \gg \ell \quad (\text{raste, ko manjšaš } \Delta) \\ \frac{\varepsilon T}{\ell} & \Delta \ll \ell \quad (\text{neodvisno od } \Delta) \end{cases} \quad (5.2)$$

Vir: A. W. van der Vaart, J. H. van Zanten (2008), kot v §1.4 — gladkost posteriornega povprečja; Wahba (1990) §1 za RKHS-Höllder ocene.

5.2 Grönwallova neenakost in bias pri dolgih intervalih

Drugi učinek dolgega Δ_i : bias-člen $L_x \varepsilon \Delta_i$ v (3.2) je zgolj linearizirana (prvi red) ocena. Za sistem, kjer napaka propagira skozi nelinearen F , natančnejšo mejo da **Grönwallova neenakost**:

Lema (Grönwall, 1919). Če $u(t) \geq 0$ zadošča $u(t) \leq \alpha + \beta \int_{t_0}^t u(s) ds$ za $\beta \geq 0$, potem

$$u(t) \leq \alpha e^{\beta(t-t_0)}. \quad (5.3)$$

Uporabljeno na propagacijo napake znotraj enega (dolgega) intervala pri napačnem c : odstopanje trajektorije od prave rešitve lahko raste kot $e^{L_x \Delta_i}$, ne le linearno z Δ_i . To je razlog, da **en sam** zelo dolg interval ($n = 1$, t.i. *single shooting*) kaznuje z eksponentno občutljivostjo na c — optimizacijska pokrajina postane skrajno nelinearna in slabo pogojena, posebej pri kaotičnih/togih (stiff) sistemih.

Vir: T. H. Grönwall, *Note on the derivatives with respect to a parameter of the solutions of a system of differential equations*, Annals of Mathematics 20(4), 1919, 292–296.

5.3 Single shooting proti multiple shooting

Integral matching z $n > 1$ intervali je natanko instanca metode **multiple shooting**: namesto da integriramo od t_0 do t_n v enem kosu (kar akumulira Grönwallovo eksponentno napako), *sidramo* trajektorijo nazaj na $\hat{x}(t_i)$ na vsakem koraku — to prepreči eksponentno kopičenje napake na račun tega, da vpeljemo n ločenih residualov (3.2), ki jih je treba nato uskladiti.

Vir: H. G. Bock, *Recent advances in parameter identification techniques for ODE*, v: P. Deuflhard, E. Hairer (ur.), *Numerical Treatment of Inverse Problems in Differential and Integral Equations*, Birkhäuser, 1983 — izvorni članek o multiple shooting za ODE parameter estimation.

5.4 Praktično vodilo

Iz (5.2) + (5.3) + §4.2 (daljši $\Delta_i \rightarrow$ boljša pogojenost G) sledi konkreten kompromis:

- $\Delta \ll \ell$: nič ne pridobiš (formula 5.2, spodnji primer) — le akumuliraš več intervalov brez nove informacije (sosednja $\hat{x}(t_i), \hat{x}(t_{i-1})$ sta pod posteriorjem skoraj ista naključna spremenljivka).
- $\Delta \gg \ell$: dno šuma na interval pada s Δ (5.2, zgornji primer), G je bolj pogojena (§4.2), a Grönwallov bias (5.3) in nelinearnost optimizacije raste.

Priporočilo: izberi Δ_i reda velikosti korelacijske dolžine GP jedra ℓ (dobiš jo direktno kot hiperparameter iz prilaganja GP). To je empirično preverljivo vodilo, ne le teoretična poanta.

6. Primerjava z gradient matchingom

6.1 Definicija gradient matchinga

Definicija 6.1. Gradient matching uporabi residual v točkah namesto integriran residual po intervalih:

$$r_i^{GM}(c) := \hat{x}'(t_i) - F(\hat{x}(t_i), t_i, c). \quad (6.1)$$

Vir: J. O. Ramsay et al. (2007), kot v §3.3; B. Calderhead, M. Girolami, N. D. Lawrence, *Accelerating Bayesian inference over nonlinear differential equations with Gaussian processes*, NeurIPS 21, 2008; P. Wenk et al., *Fast Gaussian Process Based Gradient Matching for Parameter Identification in Systems of Nonlinear ODEs*, AISTATS 2019.

6.2 Dobro in slabo postavljeni problemi

Definicija 6.2 (Hadamard). Problem je *dobro postavljen* (*well-posed*), če ima rešitev, ta je enolična in je **zvezno odvisna od podatkov**. Sicer je *slabo postavljen* (*ill-posed*).

Numerično odvajanje zašumljenih podatkov je klasičen primer slabo postavljenega problema: majhna sprememba (šum z amplitudo ε , poljubno visoke frekvence) v vhodni funkciji lahko povzroči poljubno veliko spremembo odvoda. Numerična **integracija** je nasprotno *kompakten* (gladilen) operator — dušilec visokih frekvenc — in je zato dobro postavljena.

Vir: H. W. Engl, M. Hanke, A. Neubauer, *Regularization of Inverse Problems*, Kluwer Academic Publishers, 1996, pogl. 2 — formalna obravnava odvajanja kot ill-posed problema in zakaj integracija ni.

6.3 Ojačitev šuma pri odvajanju (hevristična ocena)

Za stacionaren GP z jedrom lengthscale ℓ (1.2) posteriorna (ko)varianca odvoda vsebuje $\partial^2 k / \partial t \partial t'$, ki je za (1.2) enaka σ_f^2 / ℓ^2 pri $t = t'$ — dimenzijsko to pomeni, da je negotovost odvoda za faktor $\sim 1/\ell$ večja od negotovosti same funkcije:

$$\|e'(t)\| \sim \frac{\varepsilon}{\ell}. \quad (6.2)$$

Torej ima gradient-matching residual (6.1) dno šuma reda ε/ℓ **na točko**, medtem ko ima integral-matching residual (2.4) dno šuma reda ε **na (dovolj dolg) interval** — brez faktorja $1/\ell$.

Vir: Rasmussen & Williams (2006), §9.4 (eksplicitna formula za kovarianco GP odvodov).

6.4 Limita $\Delta \rightarrow 0$: gradient matching kot degeneriran primer

Po izreku o povprečni vrednosti za integral, ko $\Delta_i \rightarrow 0$:

$$l_i(c) = \int_{t_{i-1}}^{t_i} [\hat{x}'(\tau) - F(\hat{x}(\tau), \tau, c)] d\tau + O(\Delta_i^2) \approx \Delta_i \cdot r_i^{GM}(c). \quad (6.3)$$

Torej integral matching **zvezno degenerira** v gradient matching, ko $\Delta \rightarrow 0$; iz (5.2) in (6.2) se dni ujemata natanko pri $\Delta \sim \ell$, kar potrjuje vodilo iz §5.4 iz drugega zornega kota.

6.5 Primerjalna tabela

Lastnost	Gradient matching	Integral matching ($\Delta \gtrsim \ell$)
Operacija na $\hat{x}$	odvajanje (ill-posed)	integracija (well-posed, gladi)
Dno šuma na enoto podatkov	$O(\varepsilon/\ell)$	$O(\varepsilon)$, neodvisno od ℓ
Pogojenost G (identifikabilnost)	točkovna občutljivost	integrirana občutljivost — praviloma bolje pogojena
Bias pri nelinearnem F	majhen (lokalna ocena)	raste z Δ (Grönwall, §5.2)
Degenerira v	—	gradient matching, ko $\Delta \rightarrow 0$

Odgovor na vprašanje "ali je integral matching bolj odporen na šum": da, formalno, v smislu §6.2–6.3 — a le pri $\Delta \gtrsim \ell$. Pri $\Delta \rightarrow 0$ prednost izgine, saj metodi postaneta ekvivalentni.

7. Povzetek in praktična priporočila

- Kriterij ustavitve** (§3): ne uporabljaj analitične meje (3.3) neposredno (odvisna je od neznanega L_x); kalibriraj prag za $J(c)$ z bootstrapom iz GP posteriorja.
- Identifikabilnost** (§4): izračunaj $G = \sum_i S_i^\top S_i$ in njegov spekter; majhne lastne vrednosti razkrijejo kombinacije parametrov, ki jih ti podatki ne morejo ločiti.
- Dolžina intervala** (§5): izberi Δ reda velikosti GP-jeve lengthscale ℓ ; ne sekaj bolj fino (brez pridobitve, akumuliraš šum) niti bistveno bolj grobo (Grönwallov bias, single-shooting nestabilnost).
- Primerjava z gradient matchingom** (§6): integral matching je matematično utemeljeno bolj odporen na šum, ker integracija deluje kot dobro postavljen (gladilni) operator v primerjavi z odvajanjem — a ta prednost je pogojena s $\Delta \gtrsim \ell$, sicer degenerira nazaj v gradient matching.

Literatura

- C. E. Rasmussen, C. K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006.
- A. W. van der Vaart, J. H. van Zanten. "Rates of contraction of posterior distributions based on Gaussian process priors." *Annals of Statistics* 36(3), 2008, 1435–1463.
- G. Wahba. *Spline Models for Observational Data*. SIAM, 1990.
- W. Rudin. *Principles of Mathematical Analysis*, 3rd ed. McGraw-Hill, 1976.
- E. A. Coddington, N. Levinson. *Theory of Ordinary Differential Equations*. McGraw-Hill, 1955.

6. S. Boucheron, G. Lugosi, P. Massart. *Concentration Inequalities: A Nonasymptotic Theory of Independence*. Oxford University Press, 2013.
7. J. O. Ramsay, G. Hooker, D. Campbell, J. Cao. "Parameter estimation for differential equations: a generalized smoothing approach." *JRSS-B* 69(5), 2007, 741–796.
8. G. A. F. Seber, C. J. Wild. *Nonlinear Regression*. Wiley, 2003.
9. C. Cobelli, J. J. DiStefano. "Parameter and structural identifiability concepts and ambiguities." *American Journal of Physiology* 239(1), 1980, R7–R24.
10. A. Raue et al. "Structural and practical identifiability analysis of partially observed dynamical models by exploiting the profile likelihood." *Bioinformatics* 25(15), 2009, 1923–1929.
11. T. H. Grönwall. "Note on the derivatives with respect to a parameter of the solutions of a system of differential equations." *Annals of Mathematics* 20(4), 1919, 292–296.
12. H. G. Bock. "Recent advances in parameter identification techniques for ODE." In *Numerical Treatment of Inverse Problems in Differential and Integral Equations*, eds. P. Deuflhard, E. Hairer. Birkhäuser, 1983.
13. B. Calderhead, M. Girolami, N. D. Lawrence. "Accelerating Bayesian inference over nonlinear differential equations with Gaussian processes." *NeurIPS* 21, 2008.
14. P. Wenk, A. Gotovos, S. Bauer, N. S. Gorbach, A. Krause, J. M. Buhmann. "Fast Gaussian Process Based Gradient Matching for Parameter Identification in Systems of Nonlinear ODEs." *AISTATS*, 2019.
15. H. W. Engl, M. Hanke, A. Neubauer. *Regularization of Inverse Problems*. Kluwer Academic Publishers, 1996.
16. J. Hadamard. "Sur les problèmes aux dérivées partielles et leur signification physique." *Princeton University Bulletin* 13, 1902, 49–52.