MAGI: gradient matching z neopazovanimi spremenljivkami

Kako deluje MAGI (MAnifold-constrained Gaussian process Inference, Yang, Wong, Kou 2021), kako ga prevedemo iz Bayesovskega vzorčenja v optimizacijo (MAP, "maximum likelihood") in kako bi ga implementirali v `odestimate`. Spremljevalni dokument k `gradient-matching.md`: tam je GP interpolant fiksen in izračunan samo iz podatkov, tu postanejo vrednosti trajektorije neznanke, kar omogoči tudi spremenljivke brez podatkov.

Kako brati ta dokument

- Formule, označene z **(MAGI, JSS §…)**, so prepisane iz članka o paketu MAGI (Wong, Yang, Kou, *J. Stat. Softw.* 109(4), 2024; arXiv 2203.06066), ki metodo povzame z istimi oznakami kot izvirni članek v PNAS.
- **Trditve z dokazom** so naše izpeljave. Kjer je trditev preverjena tudi numerično (na kodi v `odestimate`), je to navedeno.
- Kjer gre za hevristiko ali odprto vprašanje, je to izrecno označeno.

Povzetek v treh stavkih.

1. MAGI da GP prior *vsaki* komponenti stanja, tudi neopazovani, in vrednosti trajektorije na mreži I obravnava kot neznanke, skupaj s θ.
2. ODE vstopi kot pogoj, da je GP-jev odvod v točkah I enak f. Iz pravil pogojne verjetnosti sledi zaprta oblika posteriorja, brez numerične integracije in brez proste uteži "λ".
3. Če posterior namesto vzorčenja maksimiziramo, dobimo nelinearen problem najmanjših kvadratov velikosti $D|I| + p$, ki ga rešuje Gauss-Newton. Ima pa tri degeneracije, ki jih moramo poznati (§5.4).

---

0. Notacija

simbol	pomen
$x(t) \in \mathbb{R}^D$	stanje sistema; $x_d(t)$ je komponenta d
$\dot{x}(t)$	časovni odvod
$f(x, \theta, t) \in \mathbb{R}^D$	desna stran ODE, $\dot{x} = f(x,\theta,t)$ (v `gradient-matching.md`: F, parametri c)
$\theta \in \Omega_\theta \subset \mathbb{R}^p$	parametri (konstante modela)
τ_d	časi meritev komponente d (prazna množica, če je d neopazovana)
$y_d(\tau_d)$	meritve, $y_d(t) = x_d(t) + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma_d^2)$
$I = \{t_1, \dots, t_n\}$	diskretizacijska mreža, $\tau_d \subset I$ za vse d
$x_d(I) \in \mathbb{R}^{	I
$f_d(x(I), \theta, t_I) \in \mathbb{R}^{	I
$\mathcal{K}_d(s,t)$	kovariančna funkcija (jedro) GP-ja za komponento d
$\mu_d(t)$	povprečna funkcija priorja (privzeto 0)
ϕ_d	hiperparametri jedra (varianca, korelacijska dolžina)
$\lvert v\rvert_A^2$	$v^\top A v$
D_o, D_ℓ	indeksi opazovanih in neopazovanih (latentnih) komponent

Odvodi jedra (MAGI, JSS §4.2):

$$'\mathcal{K}(s,t) = \frac{\partial}{\partial s}\mathcal{K}(s,t), \qquad \mathcal{K}'(s,t) = \frac{\partial}{\partial t}\mathcal{K}(s,t), \qquad \mathcal{K}''(s,t) = \frac{\partial^2}{\partial s\,\partial t}\mathcal{K}(s,t).$$

Za stacionarno jedro $\mathcal{K}(s,t) = \kappa(s-t)$ velja $'\mathcal{K}(s,t) = \kappa'(s-t)$, $\mathcal{K}'(s,t) = -\kappa'(s-t)$ in $\mathcal{K}''(s,t) = -\kappa''(s-t)$. V `odestimate` je $'\mathcal{K}$ = `RBFWithNoise.gradient_X`, $\mathcal{K}''$ = `RBFWithNoise.hessian_XY`.

---

1. Zakaj navaden gradient matching tu ne zadošča

Gradient matching iz `gradient-matching.md` naredi dva ločena koraka:

1. Iz podatkov komponente d izračuna GP posteriorno povprečje $\hat{x}_d(t)$ in njegov odvod $\hat{x}_d'(t)$. Ti dve funkciji sta od tu naprej **fiksni**.
2. Poišče θ, ki minimizira $\sum_i \|\hat{x}'(t_i) - f(\hat{x}(t_i), \theta, t_i)\|^2$.

Za neopazovano komponento korak 1 ni mogoč: brez podatkov ni $\hat{x}_\ell$ in ne $\hat{x}_\ell'$. Ker f v splošnem bere vse komponente (npr. plenilec v enačbi plena), ostanek tudi za opazovane komponente ni izračunljiv.

Avtorji MAGI izpostavijo še bolj načelen problem prejšnjih GP pristopov (Calderhead et al. 2009, Dondelinger et al. 2013, Wenk et al. 2019): $\dot{x}$ je tam podan **dvakrat in nezdružljivo**, enkrat z GP-jem (kot odvod interpolanta) in enkrat z ODE (f). Ta dva opisa so nato združevali s hevristikami (npr. produktom dveh gostot z dodatnim parametrom tolerance). MAGI namesto tega GP *pogoji* na to, da njegov odvod zadošča ODE, kar je ena sama koherentna verjetnostna konstrukcija (MAGI, JSS §2).

---

2. Gradniki: GP in njegov odvod

2.1 Skupna porazdelitev vrednosti in odvoda

Definicija 2.1. Komponenti d damo GP prior $X_d \sim \mathcal{GP}(\mu_d, \mathcal{K}_d)$, komponente med sabo neodvisne. Če je $\mathcal{K}_d$ dovolj gladko jedro (§3.7), je proces v srednjem kvadratnem odvedljiv, $\dot{X}_d$ je spet GP, in ker je odvajanje linearna operacija, je par $(X_d(I), \dot{X}_d(I))$ skupno Gaussovski:

$$\begin{pmatrix} X_d(I) \\ \dot{X}_d(I) \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_d(I) \\ \dot{\mu}_d(I) \end{pmatrix}, \begin{pmatrix} \mathcal{K}_d(I,I) & \mathcal{K}_d'(I,I) \\ {}'\mathcal{K}_d(I,I) & \mathcal{K}_d''(I,I) \end{pmatrix} \right). \tag{2.1}$$

Kovarianci izhajata iz $\mathrm{Cov}[\dot{X}(s), X(t)] = \partial_s \mathcal{K}(s,t)$ in $\mathrm{Cov}[\dot{X}(s), \dot{X}(t)] = \partial_s\partial_t \mathcal{K}(s,t)$ (Solak et al. 2003; Rasmussen in Williams 2006, §9.4; enako kot (1.1) v `gradient-matching.md`). Ker je $\mathcal{K}$ simetrično, velja $\mathcal{K}_d'(I,I) = {}'\mathcal{K}_d(I,I)^\top$.

2.2 Odvod pri danih vrednostih

Trditev 2.2 (MAGI, JSS §4.2). Pri danem $X_d(I) = x_d(I)$ velja

$$\dot{X}_d(I) \mid X_d(I) = x_d(I) \;\sim\; \mathcal{N}\big(\dot{\mu}_d(I) + m_d\,\{x_d(I) - \mu_d(I)\},\; \Psi_d\big), \tag{2.2}$$

$$C_d = \mathcal{K}_d(I,I), \qquad m_d = {}'\mathcal{K}_d(I,I)\, C_d^{-1}, \qquad \Psi_d = \mathcal{K}_d''(I,I) - {}'\mathcal{K}_d(I,I)\, C_d^{-1}\, \mathcal{K}_d'(I,I).$$

C_d je kovarianca $x_d(I)$, m_d preslika vrednosti v pričakovani odvod, Ψ_d je kovarianca odvoda, ki ostane, ko vrednosti poznamo.

Dokaz. Standardna formula za pogojno porazdelitev pri skupno Gaussovskem paru (a, b): $b \mid a \sim \mathcal{N}\big(\mu_b + \Sigma_{ba}\Sigma_{aa}^{-1}(a - \mu_a),\; \Sigma_{bb} - \Sigma_{ba}\Sigma_{aa}^{-1}\Sigma_{ab}\big)$ (Schurov komplement). Vstavimo $a = X_d(I), b = \dot{X}_d(I)$ in bloke iz (2.1). ■

2.3 Kaj m_d in Ψ_d pomenita

Trditev 2.3. $\dot{\mu}_d(I) + m_d\{x_d(I) - \mu_d(I)\}$ je natanko odvod (v točkah I) brezšumnega GP interpolanta skozi točke $(I, x_d(I))$.

Dokaz. GP, pogojen na $X_d(I) = x_d(I)$ brez šuma, ima povprečje $\mu_d(t) + \mathcal{K}_d(t,I)\, C_d^{-1}\{x_d(I) - \mu_d(I)\}$. Odvajamo po t in vstavimo $t \in I$. ■

m_d je torej "odvajanje prek interpolacije", linearna operacija na vrednostih. To je natanko tvoja ideja s "seedi": vrednosti v I so seedi, m_d da odvod interpolanta skozi njih.

Trditev 2.4. Če mrežo I zgoščujemo okoli t_i, gre $(\Psi_d)_{ii} \to 0$.

Dokaz. Pogojna varianca je najmanjša srednja kvadratna napaka med vsemi ocenami iz $X_d(I)$, torej tudi manjša od napake ocene z diferenčnim kvocientom: če $t_i \pm h \in I$, je $(\Psi_d)_{ii} \le \mathbb{E}\big[\big(\dot{X}_d(t_i) - \frac{X_d(t_i+h) - X_d(t_i-h)}{2h}\big)^2\big] \to 0$ za $h \to 0$, ker je $\dot{X}_d$ odvod v srednjem kvadratnem. ■

Posledica za §3: teža ODE pogoja Ψ_d^{-1} z gostoto mreže raste, gostejša mreža torej strožje uveljavlja ODE. Hkrati C_d in Ψ_d postajata slabo pogojeni (§6.7).

---

3. MAGI

3.1 Mnogoterost rešitev ODE

(MAGI, JSS §2.) Množica trajektorij, ki zadoščajo ODE za neki θ:

$$\mathcal{X} = \big\{ x : [0,T] \to \mathbb{R}^D \;\big|\; x_d \in C^1[0,T],\; \dot{x}(t) = f(x(t), \theta, t)\;\forall t \in [0,T],\; \text{za neki } \theta \in \Omega_\theta \big\}.$$

Slučajna spremenljivka, ki meri odstopanje GP-jeve trajektorije od te množice:

$$W = \sup_{t \in [0,T],\, d} \big| \dot{X}_d(t) - f(X(t), \theta, t)_d \big|.$$

$W = 0$ natanko tedaj, ko je realizacija X rešitev ODE. Idealni posterior bi bil $p(\theta, x \mid W = 0,\, y(\tau))$.

3.2 Diskretizacija

Pogoja $W = 0$ na zveznem intervalu ne znamo izračunati, zato ga nadomestimo z diskretnim:

$$W_I = \max_{t \in I,\, d} \left| \dot{X}_d(t) - f(X(t), \theta, t)_d \right|, \qquad \tau \subset I.$$

$W_I = 0$ pomeni: odvod GP-ja je enak f **v vsaki točki mreže**, med točkami pa ne nujno.

3.3 Posterior

(MAGI, JSS §2, enačba (3).) Po Bayesovem pravilu:

$$p(\theta, x(I) \mid W_I = 0, y(\tau)) \;\propto\; \pi(\theta) \;\times\; p(x(I)) \;\times\; p(y(\tau) \mid x(I)) \;\times\; p\big(\dot{X}(I) = f(x(I), \theta, t_I) \;\big|\; x(I)\big). \tag{3.1}$$

Štirje faktorji:

1. $\pi(\theta)$ je prior parametrov.
2. $p(x(I))$ je GP prior na mreži, $\mathcal{N}(\mu_d(I), C_d)$ za vsako komponento. **Ne** vključuje podatkov.
3. $p(y(\tau) \mid x(I)) = p(y(\tau) \mid x(\tau))$ je verjetje meritev. Ker $\tau \subset I$, so $x(\tau)$ kar nekatere izmed neznank.
4. Gostota (2.2) odvoda pri danih vrednostih, **ovrednotena pri** $\dot{X}(I) = f$. Iz tega faktorja pride ODE.

Poenostavitve, ki jih članek uporabi: GP prior in meritve so neodvisni od θ, odvod pri danih vrednostih pa je pogojno neodvisen od θ in od meritev. Zato $p(W_I = 0 \mid y, x(I), \theta) = p(\dot{X}(I) = f(x(I), \theta, t_I) \mid x(I))$.

Opomba 3.1 (pogojevanje na dogodek z verjetnostjo 0; naša opomba). $W_I = 0$ ima verjetnost 0, zato je "pogojevanje" nanj treba razumeti kot limito, rezultat pa je lahko odvisen od izbire limite (Borel-Kolmogorov paradoks). Tu je enoličen. Naj bo $U = \dot{X}(I) - f(X(I), \theta, t_I) \in \mathbb{R}^{D|I|}$. Velja $W_I = \|U\|_\infty$. Pri danih $(\theta, x(I))$ je U le premik $\dot{X}(I)$, z Jacobijevo determinanto 1, zato je pogojna gostota U v 0 enaka gostoti (2.2) v f. Če $W_I = 0$ razumemo kot limito dogodkov $\{\|U\|_\infty < \epsilon\}$, je njihova prostornina $(2\epsilon)^{D|I|}$ neodvisna od (θ, x) in se v (3.1) okrajša. Isto bi dobili z $\|U\|_2 < \epsilon$. Drugačen rezultat bi dobili le, če bi pogoj zapisali z nelinearno transformacijo U, ki je odvisna od (θ, x).

3.4 Logaritem posteriorja

Pri fiksnih ϕ in σ ter s temperiranjem β iz §3.5:

$$\begin{aligned}\mathcal{L}(\theta, x(I)) := -\log p(\theta, x(I) \mid W_I = 0, y) = \sum_{d=1}^{D} \Big[\frac{1}{2\sigma_d^2} \big\| x_d(\tau_d) - y_d(\tau_d) \big\|^2 + \frac{1}{2\beta} \big\| x_d(I) - \mu_d(I) \big\|^2_{C_d^{-1}} \\ + \frac{1}{2\beta} \big\| f_d(x(I), \theta, t_I) - \dot{\mu}_d(I) - m_d\{x_d(I) - \mu_d(I)\} \big\|^2_{\Psi_d^{-1}} \Big] - \log \pi(\theta) + \text{konst.}\end{aligned} \tag{3.2}$$

$$\text{konst.} = \sum_d \Big[\tfrac{|\tau_d|}{2} \log(2\pi\sigma_d^2) + \tfrac{1}{2\beta} \big(2|I| \log 2\pi + \log\det C_d + \log\det \Psi_d \big) \Big].$$

Tri člene beremo takole:

- **podatki:** x naj bo blizu meritev;
- **prior:** x naj bo gladka trajektorija prave velikosti, kot jo dopušča jedro;
- **ODE:** odvod interpolanta skozi $x(I)$ naj bo enak f.

Vsi trije so kvadratne forme. Nelinearnost je samo v f.

Pomembno je, da f_d bere vrednosti **vseh** komponent v istem času, zato ODE člen sklaplja komponente. Prek tega sklopa pride informacija do neopazovanih komponent (§3.6).

3.5 Temperiranje β

(MAGI, JSS §4.1.) Člena 2 in 3 v (3.2) imata skupaj $2D|I|$ prispevkov, podatkovni člen pa le $N = \sum_d |\tau_d|$. Z gostitvijo mreže bi GP člena prevladala nad podatki. MAGI zato produkt $p(x(I))\, p(\dot{X}(I) = f \mid x(I))$ potencira na $1/\beta$, s priporočeno vrednostjo

$$\beta = \frac{D\,|I|}{\sum_{d=1}^{D} |\tau_d|} \qquad (\text{število točk mreže} \,/\, \text{število meritev, čez vse komponente}).$$

Če se $|I|$ podvoji, se prispevek GP členov na log-skali razpolovi.

- To je hevristika za stabilnost ocen pri zaporedju gostejših mrež, ne posledica verjetnostnega modela. Temperirani (3.1) ni več pravi posterior.
- **Neskladje v članku:** v seznamu nastavitev (`priorTemperature`, JSS §3) je privzeta vrednost opisana obratno, kot "število meritev / število točk mreže". Po §4.1 in po namenu (deli log-prior, zmanjša GP z gostejšo mrežo) je pravilno $D|I|/N$.
- Neopazovane komponente imajo $|\tau_d| = 0$, zato povečajo β.

3.6 Neopazovane komponente

Za neopazovano komponento ℓ v (3.2) podatkovnega člena ni. Njen $x_\ell(I)$ je določen samo s tremi stvarmi:

1. z njeno lastno ODE ($\dot{x}_\ell \approx f_\ell$);
2. s sklopom: x_ℓ nastopa v f_d opazovanih komponent, katerih ODE člen je vezan na podatke;
3. s priorjem (gladkost, velikost).

Ali to zadošča za določitev x_ℓ in θ, je vprašanje identifikabilnosti modela, ne metode. Kjer model ni identifikabilen, se MAP obnaša slabo, glej §5.4.

3.7 Hiperparametri in jedro

(MAGI, JSS §2 in §4.2.) MAGI teče v treh korakih:

1. **Opazovane komponente:** ϕ_d in σ_d dobi z GP fitom na podatke (MAP s šibkim normalnim priorjem na korelacijsko dolžino). Začetni $x_d(I)$ je linearna interpolacija meritev.
2. **Neopazovane komponente:** ϕ_ℓ, $x_\ell(I)$ in θ dobi s skupno optimizacijo (3.2), pri fiksnih vrednostih za opazovane komponente iz koraka 1. Brez neopazovanih komponent optimizira le θ. To so začetne vrednosti za korak 3.
3. **HMC** vzorči $(\theta, x(I))$, in σ, če ni znan. ϕ je med vzorčenjem fiksen.

Jedro. Privzeto je Matérnovo jedro z $\nu = 2.01$:

$$\mathcal{K}(s,t) = \phi_1 \frac{2^{1-\nu}}{\Gamma(\nu)} \Big(\sqrt{2\nu}\,\tfrac{r}{\phi_2}\Big)^{\nu} B_\nu\Big(\sqrt{2\nu}\,\tfrac{r}{\phi_2}\Big), \qquad r = |s-t|,$$

kjer je ϕ_1 varianca, ϕ_2 korelacijska dolžina, B_ν pa modificirana Besslova funkcija druge vrste.

Zakaj Matérn in ne RBF: za (2.1) mora $\dot{X}$ obstajati. Matérnov proces je k-krat odvedljiv v srednjem kvadratnem natanko tedaj, ko $\nu > k$ (Rasmussen in Williams 2006, §4.2.1), za en odvod torej zadošča $\nu > 1$. MAGI izbere $\nu = 2.01$ in navaja, da so gladkejša jedra (Matérn 5/2, RBF) preveč gladka za ostre spremembe in vodijo v pristranske ocene θ. Naš `RBFWithNoise` je neskončno gladek, za watershed s `max(0, ·)`, if-else in dnevnimi skoki vhodov torej ravno najslabša izbira (glej §6.6).

Še dve privzeti nastavitvi: povprečje priorja je 0, opcija `positiveSystem` pa vsili $x \geq 0$.

3.8 Vzorčenje (HMC)

Hamiltonov Monte Carlo vzorči iz gostote $\propto e^{-\mathcal{L}(z)}$, $z = (\theta, x(I))$. Na gibalni količini $q \sim \mathcal{N}(0, M)$ simulira Hamiltonovo dinamiko z energijo $\mathcal{L}(z) + \frac{1}{2} q^\top M^{-1} q$ v L "leapfrog" korakih, vsak korak pa rabi gradient $\nabla \mathcal{L}$. Na koncu predlog sprejme ali zavrne z Metropolisovim pravilom.

Privzete nastavitve MAGI so 20 000 iteracij × 200 korakov, polovica iteracij je burn-in, korak pa se med burn-inom nastavi na 60–90 % sprejetih predlogov (MAGI, JSS §3). To je $4 \cdot 10^6$ izračunov $\nabla \mathcal{L}$ na en model: odlično za en model in njegovo negotovost, za presejanje tisočih kandidatov pa preveč.

3.9 Kaj MAGI ni

- ODE je izpolnjena **samo v točkah** I. Med njimi trajektorijo določa GP interpolacija. Pri ostrih spremembah v f je treba mrežo zgostiti ali skrajšati ϕ_2 (MAGI, JSS §4.2, opomba 3).
- MAGI priporoča zaporedje mrež $I_0 \subset I_1 \subset \cdots$, kjer je I_0 najmanjša enakomerna mreža, ki vsebuje τ, vsaka naslednja pa ima med sosednjima točkama vrinjeno novo točko. Ocene naj bodo stabilne čez to zaporedje (MAGI, JSS §4.1).
- Numerične integracije ni nikjer. Je pa linearna algebra z matrikami $|I| \times |I|$.

---

4. Povezava z našim gradient matchingom in s seedi

Trditev 4.1. Naj bo $\tau \subset I$, naj bo prior MAGI enak GP-ju, s katerim gladimo podatke (isti $\mathcal{K}_d$, μ_d), in naj $\hat{x}_d$ označuje GP posteriorno povprečje iz podatkov. Potem je pri $x_d(I) = \hat{x}_d(I)$ ODE ostanek MAGI natanko ostanek gradient matchinga:

$$\dot{\mu}_d(I) + m_d\{\hat{x}_d(I) - \mu_d(I)\} = \hat{x}_d'(I).$$

Dokaz. Posteriorno povprečje je $\hat{x}_d(t) = \mu_d(t) + \mathcal{K}_d(t,\tau)\alpha$ z $\alpha = (\mathcal{K}_d(\tau,\tau) + \sigma_d^2 I)^{-1}(y_d - \mu_d(\tau))$, njegov odvod pa $\hat{x}'_d(t) = \dot{\mu}_d(t) + {}'\mathcal{K}_d(t,\tau)\alpha$. Ker je $\tau \subset I$, je $\mathcal{K}_d(I,\tau) = C_d E_\tau$, kjer E_τ izbere stolpce, ki pripadajo τ. Zato $C_d^{-1}\mathcal{K}_d(I,\tau) = E_\tau$ in

$$m_d\{\hat{x}_d(I) - \mu_d(I)\} = {}'\mathcal{K}_d(I,I)\, C_d^{-1}\mathcal{K}_d(I,\tau)\,\alpha = {}'\mathcal{K}_d(I,I)E_\tau\alpha = {}'\mathcal{K}_d(I,\tau)\alpha = \hat{x}'_d(I) - \dot{\mu}_d(I). \qquad \blacksquare$$

Numerično preverjeno z `GP1dim` (RBF, 25 meritev $\sin t$ s šumom, $I = \tau \cup$ sredine): razlika je $1.2 \cdot 10^{-8}$ pri jitterju $10^{-10}\max\operatorname{diag} C$ in raste z jitterjem (tabela v §6.7).

Posledice:

- **Najin gradient matching je MAGI-MAP z zamrznjenimi vrednostmi** $x(I) = \hat{x}(I)$, brez prior člena in z identiteto namesto uteži Ψ_d^{-1}. MAGI te vrednosti "odmrzne": opazovane komponente se smejo odmakniti od glajenja podatkov, kjer to zahteva ODE, neopazovane pa sploh postanejo mogoče.
- **Tvoja ideja s seedi je MAGI**: seedi so $x_\ell(I)$, interpolant skozi njih da m_ℓ (Trditev 2.3), regularizacija je prior člen $\|x_\ell\|^2_{C_\ell^{-1}}$, utež "$\lambda$" pa ni prosta, ampak je Ψ_ℓ^{-1}/β, določena z jedrom in mrežo.
- **Število seedov**: s prior členom več točk mreže ne pokvari rešitve, temveč le podraži linearno algebro, in MAGI ravno priporoča gostitev, dokler se ocene ne ustalijo.

---

5. Od Bayesa do optimizacije

5.1 MAP

$$(\hat{\theta}, \hat{x}(I)) = \arg\min_{\theta\in\Omega_\theta,\, x(I)} \mathcal{L}(\theta, x(I)),$$

z $\mathcal{L}$ iz (3.2), pri fiksnih ϕ in σ. To je natanko korak 2 iz §3.7, brez optimizacije ϕ. **MAGI-MAP je MAGI brez HMC**.

5.2 Ali je to "maximum likelihood"?

Ne povsem. Ločiti moramo dve količini:

- **Marginalno verjetje** θ (pravi ML) integrira trajektorijo:

$$\mathcal{M}(\theta) = \int p(y \mid x)\, p(x)\, p(\dot{X}(I) = f \mid x)\, dx(I).$$

  To je integral v $D|I|$ dimenzijah, ki ga ne znamo izračunati v zaprti obliki.
- **Skupno verjetje**, maksimizirano po x (profil, v duhu h-likelihooda Leeja in Nelderja): $\ell_p(\theta) = -\min_x \mathcal{L}(\theta, x)$. Pri ravnem priorju na θ je MAP $\hat{\theta}$ ravno $\arg\max \ell_p$.

Povezuje ju **Laplaceova aproksimacija** (Tierney in Kadane 1986). Naj bo $\hat{x}(\theta) = \arg\min_x \mathcal{L}(\theta, x)$ in $H(\theta) = \nabla_x^2 \mathcal{L}(\theta, \hat{x}(\theta)) \succ 0$:

$$\log \mathcal{M}(\theta) \approx \ell_p(\theta) + \frac{D|I|}{2}\log 2\pi - \frac{1}{2}\log\det H(\theta). \tag{5.1}$$

- Za **ocenjevanje** θ je razlika majhna, kadar je $H(\theta)$ šibko odvisna od θ (podatki dobro določajo x). Pri neopazovanih komponentah to ne drži nujno.
- Za **primerjavo struktur** (različni f) je člen $\log\det H$ različen med kandidati in deluje kot Occamov faktor. Za primerjavo kandidatov z različnim številom parametrov bi rabili še Laplace po θ, s pravim (normaliziranim) priorjem, npr. enakomernim na `range` konstant.
- Zaradi temperiranja (§3.5) $\mathcal{M}$ ni prava gostota podatkov, zato je to vrednost za razvrščanje, ne za statistični test.

5.3 Zapis kot nelinearni najmanjši kvadrati

Za $A = LL^\top$ (Cholesky) velja $\|v\|^2_{A^{-1}} = \|L^{-1}v\|^2$. Zato je $\mathcal{L} = \tfrac{1}{2}\|R(z)\|^2 + \text{konst.} - \log\pi(\theta)$, $z = (x(I), \theta) \in \mathbb{R}^{D|I|+p}$, z ostanki:

$$\begin{aligned}
R_d^{\text{pod}} &= \big(x_d(\tau_d) - y_d\big)/\sigma_d && \in \mathbb{R}^{|\tau_d|},\\
R_d^{\text{prior}} &= \beta^{-1/2}\, L_{C_d}^{-1}\big(x_d(I) - \mu_d(I)\big) && \in \mathbb{R}^{|I|},\\
R_d^{\text{ODE}} &= \beta^{-1/2}\, L_{\Psi_d}^{-1}\big(f_d(x(I),\theta,t_I) - \dot{\mu}_d(I) - m_d\{x_d(I) - \mu_d(I)\}\big) && \in \mathbb{R}^{|I|}.
\end{aligned}$$

Raven prior na `range` konstant pomeni meje na θ, kar `scipy.optimize.least_squares(method="trf")` podpira neposredno. Podatkovni in prior ostanki so linearni v x, nelinearen je samo ODE ostanek, prek f. Če je f linearen v x, je pri fiksnem θ problem po x linearen in ima zaprto rešitev.

5.4 Degeneracije MAP

Bayesovsko vzorčenje gleda **maso** posteriorja, MAP pa njegov **vrh**. Pri modelih z latentnimi spremenljivkami ima lahko gostota neskončen vrh na mestu, kjer je mase malo. Spodnje tri trditve povedo, česa MAP ne sme optimizirati.

Trditev 5.1 (šum). Če σ_d opazovane komponente optimiziramo skupaj z x, je $\inf \mathcal{L} = -\infty$.

Dokaz. Postavimo $x_d(\tau_d) = y_d$. Podatkovni del $\mathcal{L}$ je potem $|\tau_d| \log \sigma_d + \mathrm{konst.} \to -\infty$ za $\sigma_d \to 0$, ostali členi pa so končni. ■

σ_d zato fiksiramo iz GP fita (korak 1). MAGI σ sme vzorčiti, ker je masa okoli $\sigma \to 0$ končna (integral verjetja po $x_d(\tau_d)$ je 1), čeprav je gostota tam neomejena.

Trditev 5.2 (varianca latentnega priorja). Naj bo $\mu_\ell = 0$ in naj obstajata $\theta^* \in \Omega_\theta$ in opazovani del $x_o(I)$, pri katerih $x_\ell \equiv 0$ reši latentno enačbo, $f_\ell(x_o(I), 0, \theta^*, t_I) = 0$. Če varianco $\phi_{\ell,1}$ optimiziramo skupaj z x, je $\inf \mathcal{L} = -\infty$.

Dokaz. Jedro je linearno v ϕ_1, zato $C_\ell = \phi_1 \tilde{C}_\ell$, $\Psi_\ell = \phi_1 \tilde{\Psi}_\ell$, m_ℓ pa od ϕ_1 ni odvisen. Pri $x_\ell = 0$ in $\theta = \theta^*$ izgineta obe latentni kvadratni formi. Od latentnega bloka ostane $\frac{1}{2\beta}(\log\det C_\ell + \log\det \Psi_\ell) = \frac{|I|}{\beta} \log \phi_1 + \mathrm{konst.} \to -\infty$ za $\phi_1 \to 0$, preostanek pa je končen. ■

Primer: Lotka-Volterra s skrito x_2: $f_2 = -c\, x_2 + d\, x_1 x_2$ je pri $x_2 \equiv 0$ enak 0 za vsak θ. MAGI v koraku 2 ϕ_ℓ optimizira. Ali v praksi pade v to degeneracijo, je odvisno od začetka in v članku ni obravnavano. Pri MAP ϕ_ℓ fiksiramo ali omejimo navzdol.

Trditev 5.3 (simetrija skale). Naj bo $\mu_\ell = 0$ in naj za $\lambda \in (0, 1]$ obstaja preslikava $\theta \mapsto \theta_\lambda \in \Omega_\theta$, za katero velja za vse x, t:

$$f_o(x_o, \lambda x_\ell, \theta_\lambda, t) = f_o(x_o, x_\ell, \theta, t), \qquad f_\ell(x_o, \lambda x_\ell, \theta_\lambda, t) = \lambda\, f_\ell(x_o, x_\ell, \theta, t).$$

Potem je $\mathcal{L}(\theta_\lambda, x_o, \lambda x_\ell) = A + \lambda^2 B$, kjer A in $B \geq 0$ nista odvisna od λ, in $B > 0$ za $x_\ell \neq 0$. Minimum zato ni dosežen pri $x_\ell \neq 0$: MAP drsi proti $\lambda \to 0$, torej $x_\ell \to 0$, θ_λ pa proti robu Ω_θ.

Dokaz. Podatkovni in prior člen opazovanih komponent x_ℓ ne vsebujeta. ODE člen opazovanih komponent vsebuje f_o, ki je po predpostavki invarianten. Latentni prior je $\lambda^2 \|x_\ell\|^2_{C_\ell^{-1}}$, latentni ODE ostanek pa $f_\ell(\cdot, \lambda x_\ell, \theta_\lambda) - m_\ell \lambda x_\ell = \lambda(f_\ell - m_\ell x_\ell)$. Torej je $B = \frac{1}{2\beta}\big(\|x_\ell\|^2_{C_\ell^{-1}} + \|f_\ell - m_\ell x_\ell\|^2_{\Psi_\ell^{-1}}\big)$, ki je pozitiven, ker je $C_\ell \succ 0$. ■

Primer: Lotka-Volterra s skrito x_2: $\theta_\lambda = (a,\ b/\lambda,\ c,\ d)$. To je ista neidentifikabilnost, ki smo jo videli pri `ms` (določen je le $b \cdot x_2$). Pri `ms` je bila smer **ravna**, pri MAP pa **pada** proti robu, ker prior nagrajuje majhen x_ℓ.

Kaj storiti: simetrijo fiksiramo, preden fitamo. Možnosti so fiksirati eno konstanto (npr. b), fiksirati $x_\ell(t_0)$ na znano vrednost, ali μ_ℓ postaviti na verjetno raven. Pri watershedu je podobna (približna) simetrija premik: `uszDelta` $+\delta$ in `soilWaterCapacity` $+\delta$ dajeta isto perkolacijo, dokler omejitev ET ne zagrabi. Prior z $\mu = 0$ bi oboje vlekel navzdol.

5.5 Negotovost brez HMC

Gauss-Newtonov Hessian $J^\top J$ v MAP točki da Laplaceovo aproksimacijo posteriorja, $z \mid y \approx \mathcal{N}(\hat{z}, (J^\top J)^{-1})$. Ustrezni blok da približne intervale za θ, kar je praktično zastonj, ker J že imamo. Velja pa le, če je posterior približno Gaussovski in nobena meja ni aktivna. Zaradi temperiranja so to intervali temperiranega posteriorja. Taki intervali bi lahko nadomestili najin interval zaupanja pri rezanju kandidatov.

---

6. Implementacija v `odestimate`

6.1 Vmesnik

Po vzoru `latent.multishooting.ms`, da ga PyBM adapter kliče na enak način:

```
def magi_map(f, ts, xs, theta_0, unobserved=None, grid=None, gps=None, latent_kernels=None,
             mu=None, beta=None, bounds=None, engine="torch", unobserved_inits=None,
             **least_squares_kwargs) -> OptimizeResult:
    """xs: (n, D), stolpci v `unobserved` so NaN. grid: I (privzeto najmanjša enakomerna mreža, ki
    vsebuje ts). gps: fitani GP1dim za opazovane komponente (sicer fit tukaj).
    latent_kernels: fiksna jedra za neopazovane komponente.
    Vrne .theta, .x (|I|, D), .grid, .beta in .cov (Gauss-Newton, §5.5)."""
```

PyBM adapter `pybm/estimate/magi.py` je analogen `multishooting.py`: stanja s podatki so opazovana, ostala latentna, `build_problem` da f samo s konstantami, ki v enačbah nastopajo.

6.2 Predračun

Odvisen je samo od mreže I in jeder, **ne od kandidata in ne od** θ. Izračuna se enkrat in deli med vsemi kandidati, kot `precompute` pri gradient matchingu. Za vsako komponento d:

```
C   = k(I, I) + eps_C * I                # k: fitano jedro, v originalnih enotah, BREZ šuma:
                                         # RBFWithNoise: k(I[:, None], I[:, None]) z eksplicitnim
Y,
                                         # k(I[:, None]) bi na diagonalo prištel noise_var
L_C = cholesky(C)
dK  = k.gradient_X(I, I)                 # 'K(I,I)
ddK = k.hessian_XY(I, I)                 # K''(I,I)
m   = cho_solve(L_C, dK.T).T             # 'K C^-1
Psi = ddK - m @ dK.T + eps_Psi * I       # K' = 'K^T
L_P = cholesky(Psi)
shrani: inv(L_C), inv(L_P), inv(L_P) @ m  # za ostanke in Jacobian
```

Enote: `GP1dim` z `normalize_y=True` fita jedro na standardiziranih podatkih. Prior v originalnih enotah je potem $s^2\,k$, $\mu = \bar{y}$, kjer sta s in $\bar{y}$ `_y_train_std` in `_y_train_mean`.

6.3 Ostanki in Jacobian

Neznanke so $z = (x_1(I), \ldots, x_D(I), \theta)$. Ostanki so iz §5.3. Jacobian po blokih, kjer je E_{τ_d} izbirna matrika:

$$\begin{aligned}
\partial R_d^{\text{pod}}/\partial x_d &= E_{\tau_d}^{\top}/\sigma_d,\\
\partial R_d^{\text{prior}}/\partial x_d &= \beta^{-1/2} L_{C_d}^{-1},\\
\partial R_d^{\text{ODE}}/\partial x_e &= \beta^{-1/2} L_{\Psi_d}^{-1}\Big(\operatorname{diag}\big(\tfrac{\partial f_d}{\partial x_e}(t_i)\big)_{i\in I} - \delta_{de}\, m_d\Big),\\
\partial R_d^{\text{ODE}}/\partial \theta &= \beta^{-1/2} L_{\Psi_d}^{-1}\, \partial f_d(x(I),\theta,t_I)/\partial\theta.
\end{aligned}$$

f deluje po točkah, zato je $\partial f_d(t_i)/\partial x_e(t_j) = \delta_{ij}\,(F_x(t_i))_{de}$. Vse $F_x(t_i)$ dobimo z D klici `jvp` (torch) ali D batch končnimi diferencami (numpy), enako kot v `confidence_interval` in `ms`. $L^{-1}\operatorname{diag}(v)$ je L^{-1} s skaliranimi stolpci, kar stane $O(|I|^2)$. Rešuje `least_squares(method="trf", x_scale="jac", bounds=...)`.

6.4 Začetne vrednosti

Dve stopnji:

- **A:** $x_o(I) := \hat{x}_o(I)$ zamrznemo (GP povprečje), optimiziramo $(\theta, x_\ell(I))$. To je tvoja ideja s seedi. Brez latentnih komponent je to po Trditvi 4.1 najin gradient matching z utežmi Ψ^{-1}. Začetni $x_\ell(I)$ je konstanta (`unobserved_inits`), ali pa ena poceni integracija *samo latentnih* enačb s fiksnim $x_o = \hat{x}_o$. Ta je stabilnejša od integracije celega sistema, ker opazovane komponente držijo podatki.
- **B:** sprostimo vse $x(I)$ in θ in začnemo iz rešitve A.

Kot dodatna robustnost (naša ideja, ne MAGI): kontinuacija po β. Začnemo z večjim β (šibkejša GP člena) in ga zmanjšujemo do priporočene vrednosti, enako kot homotopija.

6.5 Hiperparametri v praksi

- **Opazovane komponente:** `GP1dim` na podatkih. Preveri fit: degeneracijo $\ell \to 0$ smo že videli, npr. z `normalize_y=True` na 25 točkah $\sin t$. σ_d fiksiran (Trditev 5.1).
- **Latentne komponente:** ℓ_ℓ izposojen od opazovane komponente, s katero je sklopljena, $\phi_{\ell,1}$ iz pričakovane velikosti, μ_ℓ verjetna raven. Vse fiksno (Trditvi 5.2 in 5.3).
- $\beta = D|I|/N$ (§3.5).
- Simetrije modela odpravi, preden fitaš (Trditev 5.3).

6.6 Jedra

V `odestimate/gp/kernels.py` je samo `RBFWithNoise` (z `gradient_X` in `hessian_XY`). Za MAGI dodamo Matérn 3/2 in 5/2 v zaprti obliki. Splošni ν (npr. 2.01) bi rabil Besslove funkcije (`scipy.special.kv`). Za stacionarno jedro velja $'\mathcal{K} = \kappa'(s-t)$ in $\mathcal{K}'' = -\kappa''(s-t)$.

Matérn 3/2, $a = \sqrt{3}/\ell$, $u = a|r|$ (proces je enkrat odvedljiv, $\nu = 3/2 > 1$):

$$\kappa = \sigma^2(1+u)e^{-u}, \qquad \kappa' = -\sigma^2 a^2\, r\, e^{-u}, \qquad -\kappa'' = \sigma^2 a^2(1-u)e^{-u}.$$

Matérn 5/2, $a = \sqrt{5}/\ell$, $u = a|r|$:

$$\kappa = \sigma^2\big(1+u+\tfrac{u^2}{3}\big)e^{-u}, \qquad \kappa' = -\sigma^2\tfrac{a^2 r}{3}(1+u)e^{-u}, \qquad -\kappa'' = \sigma^2\tfrac{a^2}{3}\big(1+u-u^2\big)e^{-u}.$$

Numerično preverjeno s končnimi diferencami: napaka κ' je $\sim 10^{-10}$, napaka κ'' $\sim 10^{-6}$ (red diferenčne sheme). Velja tudi $\operatorname{Var}\dot{X} = -\kappa''(0)$, torej $3\sigma^2/\ell^2$ oziroma $5\sigma^2/(3\ell^2)$.

6.7 Numerika

Pogojenost. Pri RBF z $\ell \approx 2$ na 49 točkah v $[0, 10]$ smo izmerili $\mathrm{cond}(C) = 1.7 \cdot 10^{19}$. Cholesky brez dodatka na diagonali odpove. Dodatek $\varepsilon \max \mathrm{diag}\, C$ to reši, pokvari pa identiteto iz Trditve 4.1:

ε	10^{-10}	10^{-8}	10^{-6}	10^{-4}
$\max\lvert m\hat{x} - \hat{x}'\rvert$	$1.2 \cdot 10^{-8}$	$9.1 \cdot 10^{-7}$	$1.2 \cdot 10^{-4}$	$5.0 \cdot 10^{-3}$

(Velikost $\hat{x}'$ je reda 1.) Ψ_d je pogojena še slabše (Trditev 2.4). Manj gladka jedra (Matérn) so bolje pogojena, kar je dodaten razlog zanje.

Velike mreže. Za $|I|$ v tisočih (watershed: 2557 dni) MAGI aproksimira C_d^{-1}, Ψ_d^{-1} in m_d s pasovnimi matrikami (`bandSize = 20`, JSS §4.2). Za nas to pomeni: Cholesky pasovne natančnostne matrike je pasoven, Jacobian je zato redek, kar omogoči `least_squares(tr_solver="lsmr", jac_sparsity=...)`. Pasovna aproksimacija inverza pa ni nujno pozitivno definitna, kar MAGI tudi zazna in opozori.

6.8 Cena

	`ms` (multiple shooting)	MAGI-MAP
neznanke	$n_{\mathrm{sub}} D + p$	$D\lvert I\rvert + p$
ODE izpolnjena	natančno (do integratorja), na celem intervalu	mehko, v točkah I
integracija	da, vsaka iteracija	ne
na iteracijo	integracije $\times (1 + D + p)$ kopij	f, F_x, F_θ v $\lvert I\rvert$ točkah; $O(D^2\lvert I\rvert^2)$ za Jacobian; $O((D\lvert I\rvert)^3)$ za korak (gosto)
enkratno	–	$O(D\lvert I\rvert^3)$ predračun, deljen med kandidati
razpad pri slabem θ	da (`int_threshold`)	ne

Pri $|I| \lesssim 500$ je gosta varianta preprosta in hitra, nad tem rabimo pasovno.

6.9 Testni načrt

1. **Trditev 4.1:** brez latentnih komponent in z zamrznjenim x mora MAGI-MAP dati isti θ kot `gradient_matching` z utežmi Ψ^{-1}. Identiteto ostankov smo že preverili.
2. **Lotka-Volterra s skrito x_2:** brez fiksiranja simetrije mora b zdrsniti k meji (Trditev 5.3). S fiksnim b (ali primerjavo $b \cdot x_2(0)$) primerjamo z `ms`.
3. **Hes1 s skrito komponento H:** glavni primer MAGI (JSS §3). Podatke generiramo sami.
4. **Watershed s skritim `uszDelta`:** primerjava z `ms` ($cn \approx 60$, `coverCoeff` ≈ 0.8, $rc + sc \approx 0.15$) po rezultatu in času.
5. **Zaporedje mrež $I_0 \subset I_1 \subset I_2$:** ocene naj se ustalijo.

6.10 Odprta vprašanja

- **Merilo za razvrščanje kandidatov:** $\ell_p(\hat{\theta})$ ali Laplaceov (5.1) (§5.2)? Pri neopazovanih komponentah se lahko razlikujeta.
- **Opazovanje funkcije stanj.** Ker so vrednosti $x(\tau)$ eksplicitne neznanke, se meritev algebraične spremenljivke (npr. pretok, $y = g(x, \theta, t) + \varepsilon$) vključi preprosto: $R^{\mathrm{pod}} = (g(x(\tau), \theta, \tau) - y)/\sigma$, Jacobian po verižnem pravilu. To je pri MAGI bistveno lažje kot pri `ms`, in prav to rabimo za watershed. Vsa stanja so takrat latentna, zato vprašanje hiperparametrov iz §6.5 velja za vse.
- **Diskretni modeli.** Watershed (GWLF) je v resnici dnevna diferenčna enačba. Pri njej bi bil pravilnejši pogoj $x_{i+1} - x_i = h\, f(x_i)$ namesto $\dot{x} = f$. Ta "diferenčni MAGI" ne potrebuje odvoda GP-ja in je blizu šibko vezanemu 4D-Var oziroma glajenju stanj. Vredno bi ga bilo primerjati.
- **Neposredna uporaba MAGI kot reference.** Python verzija zahteva prevajanje iz izvorne kode (`build.sh`, `pymagi/py_build.sh`) in Jacobiana `fOdeDx` ter `fOdeDtheta`. Te lahko zgradimo iz PyBM torch f s `torch.func`.

---

7. Viri

- S. Yang, S. W. K. Wong, S. C. Kou (2021), *Inference of dynamic systems from noisy and sparse data via manifold-constrained Gaussian processes*, PNAS 118(15), e2020397118. doi:10.1073/pnas.2020397118
- S. W. K. Wong, S. Yang, S. C. Kou (2024), *magi: A Package for Inference of Dynamic Systems from Noisy and Sparse Data via Manifold-Constrained Gaussian Processes*, J. Stat. Softw. 109(4). doi:10.18637/jss.v109.i04, arXiv:2203.06066. Iz tega članka so formule v §3 in §6.7.

- Koda: github.com/wongswk/magi (R, MATLAB, Python).
- C. E. Rasmussen, C. K. I. Williams (2006), *Gaussian Processes for Machine Learning*, MIT Press, §4.2.1 (Matérn, odvedljivost), §9.4 (odvodi GP-jev).
- E. Solak et al. (2003), *Derivative observations in Gaussian process models of dynamic systems*, NeurIPS 16.
- J. O. Ramsay, G. Hooker, D. Campbell, J. Cao (2007), *Parameter estimation for differential equations: a generalized smoothing approach*, JRSS-B 69(5), 741–796. Isti problem kot penalizirana regresija z B-zlepki.
- P. Wenk et al. (2020), *ODIN: ODE-Informed Regression for Parameter and State Inference in Time-Continuous Dynamical Systems*, AAAI 34(04). arXiv:1902.06278
- Y. Lee, J. A. Nelder (1996), *Hierarchical generalized linear models*, JRSS-B 58(4), 619–678 (h-likelihood).
- L. Tierney, J. B. Kadane (1986), *Accurate approximations for posterior moments and marginal densities*, JASA 81, 82–86 (Laplaceova aproksimacija).
- R. M. Neal (2011), *MCMC using Hamiltonian dynamics*, v *Handbook of Markov Chain Monte Carlo*.