

MCMC ocenjevanje parametrov ODE: kako deluje in kako se primerja z našim pristopom

Tretji spremljevalni dokument k [integral-matching.md/gradient-matching.md](#) - tokrat o TEM, KAKO Dondelinger et al. (2013, AGM) in Wenk et al. (2019, FGPM) dejansko poiščeta θ : z Markov Chain Monte Carlo (MCMC), ne s [scipy.optimize.least_squares](#) kot mi. Cilj: natančen mehanizem MCMC, kako ga oba članka konkretno uporabita na tem problemu, in pošten prevod v "kdaj bi nam dejansko pomagal".

Notacija

Deljena z [gradient-matching.md](#). Novo tukaj:

- $\pi(\cdot)$ - ciljna (nenormalizirana) gostota, iz katere hočemo vzorčiti,
- $q(x'|x)$ - predlagalna (proposal) gostota - verjetnost, da iz stanja x predlagamo premik na x' ,
- $\alpha(x'|x)$ - verjetnost sprejema predlaganega premika,
- $\theta^{(s)}$ - s -ti vzorec verige (ne točkovna ocena - CELA zaporedje vzorcev),
- PSRF - potential scale reduction factor (Gelman & Rubin 1992), diagnostika konvergence.

1. Gradniki: kako MCMC sploh deluje

1.1 Problem, ki ga MCMC rešuje

Imamo ciljno gostoto $\pi(\theta)$ (npr. posterior $p(\theta|y)$), ki jo znamo OVREDNOTITI v poljubni točki (do normalizacijske konstante), ne znamo pa iz nje neposredno VZORČITI (ni standardna oblika - Gaussova, Gamma... - iz katere bi znal generator naključnih števil izvelci vzorec direktno). MCMC to reši posredno: zgradi Markovsko verigo $\theta^{(0)}, \theta^{(1)}, \theta^{(2)}, \dots$, katere **stacionarna porazdelitev je natanko π** - če verigo poganjaš dovolj dolgo, njeni vzorci (po "burn-in" fazi) postanejo (odvisni, a) vzorci iz π .

Vir: C. P. Robert, G. Casella, *Monte Carlo Statistical Methods*, 2. izd., Springer, 2004, pogl. 6-7 - standarden učbeniški vir za MCMC teorijo.

1.2 Metropolis-Hastings algoritem

Definicija 1.2. Dana ciljna gostota π (nenormalizirana) in predlagalna gostota $q(\cdot|\theta)$. Algoritem, v vsakem koraku t :

1. Predlagaj $\theta' \sim q(\cdot|\theta^{(t)})$.
2. Izračunaj razmerje sprejema

$$\alpha(\theta'|\theta^{(t)}) = \min \left(1, \frac{\pi(\theta') q(\theta^{(t)}|\theta')}{\pi(\theta^{(t)}) q(\theta'|\theta^{(t)})} \right). \quad (1.1)$$

3. S verjetnostjo α sprejmi: $\theta^{(t+1)} = \theta'$. Sicer zavrne: $\theta^{(t+1)} = \theta^{(t)}$.

Zakaj to deluje (skica dokaza, detailed balance). Veriga ima π za stacionarno porazdelitev, če zadošča pogoju **podrobnega ravnovesja** (detailed balance):

$$\pi(\theta) q(\theta'|\theta) \alpha(\theta'|\theta) = \pi(\theta') q(\theta|\theta') \alpha(\theta|\theta'). \quad (1.2)$$

Vstavimo (1.1) v (1.2) - za primer, ko je desna stran manjša (torej $\alpha(\theta'|\theta) = 1$, $\alpha(\theta|\theta') = \pi(\theta)q(\theta'|\theta)/[\pi(\theta')q(\theta|\theta')]$):

$$\pi(\theta)q(\theta'|\theta) \cdot 1 = \pi(\theta')q(\theta|\theta') \cdot \frac{\pi(\theta)q(\theta'|\theta)}{\pi(\theta')q(\theta|\theta')} = \pi(\theta)q(\theta'|\theta). \quad \checkmark$$

Enakost drži identično - (1.2) je zadoščeno KONSTRUKCIJSKO, po definiciji α same, ne kot dodatna predpostavka. Podrobno ravnovesje implicira stacionarnost π (standarden rezultat za Markovske verige - integriraj (1.2) po θ , dobiš ravnotežno enačbo $\int \pi(\theta)P(\theta'|\theta)d\theta = \pi(\theta')$).

Vir: W. K. Hastings, *Monte Carlo sampling methods using Markov chains and their applications*, Biometrika 57, 1970, 97-109 - izvorni članek.

1.3 Random-walk Metropolis (poseben, a najpogostejši primer)

Definicija 1.3. Če je q SIMETRIČNA ($q(\theta'|\theta) = q(\theta|\theta')$ - npr. $\theta' = \theta + \epsilon$, $\epsilon \sim \mathcal{N}(0, \sigma_p^2)$), se q -razmerje v (1.1) POKRAJŠA:

$$\alpha(\theta'|\theta) = \min \left(1, \frac{\pi(\theta')}{\pi(\theta)} \right). \quad (1.3)$$

To je NATANKO shema, ki jo uporabita OBA članka (Dondelinger §3, Wenk Algorithm 1: "adding a zero mean Gaussian increment") - preprosta Gaussova motnja trenutnega stanja, sprejem/zavrnitev glede na golo RAZMERJE ciljnih gostot.

1.4 Optimalna stopnja sprejema

Trditev (Gelman, 1997). Za random-walk Metropolis na (dovolj gladki, visokodimenzionalni) ciljni gostoti je asimptotsko optimalna stopnja sprejema ≈ 0.234 - prenizka stopnja (predlogi preredko sprejeti) pomeni predloge prevelike korake (veriga se komaj premakne, ko sprejme); previsoka (skoraj vedno sprejeta) pomeni prekratke korake (veriga raziskuje prostor prepočasi). Oba članka temu sledita: Dondelinger uravnava širine predlogov, da doseže sprejem ≈ 0.25 (dovolj blizu 0.234, njihova lastna izbira).

Vir: A. Gelman, W. R. Gilks, G. O. Roberts, *Weak convergence and optimal scaling of random walk Metropolis algorithms*, Annals of Applied Probability 7(1), 1997, 110-120.

1.5 Diagnostika konvergence: PSRF (Gelman-Rubin)

Problem. MCMC verigi NIKOLI ni zagotovljeno, da je konvergirala v končnem času - lahko je "obtičala" v enem delu prostora, ne da bi sploh vedela, da obstaja drug del. En sam tek ti tega ne pove.

Rešitev (Gelman & Rubin, 1992). Poženi M neodvisnih verig z RAZLIČNIMI začetnimi točkami. Za vsak parameter primerjaj varianco ZNOTRAJ posamezne verige (W) proti varianci MED verigami (B) - če so verige res vse konvergirale k isti π , bi morali biti primerljivi. PSRF (tudi $\hat{R}$) je grobo $\sqrt{(\text{ocenjena skupna varianca})/W}$; PSRF blizu 1 pomeni "verige se strinjajo", PSRF $\gg 1$ pomeni "verige NISO konvergirale (ali obtičale v različnih predelih)". Oba članka uporabita prag PSRF < 1.1 za "dovolj konvergirano" - Dondelinger EKSPlicitno poroča, da Calderhead et al.-ov osnovni model NIKOLI ni dosegel PSRF < 1.1 pri neničelnem šumu (glej §5 tam)

- to je bil GLAVNI empirični dokaz njihove diagnoze "ta metoda je nezanesljiva pod šumom".

Vir: A. Gelman, D. B. Rubin, *Inference from iterative simulation using multiple sequences*, Statistical Science 7(4), 1992, 457-472.

1.6 Population MCMC / vzporedno temperiranje

Problem, ki ga rešuje. Random-walk Metropolis lahko obtiči v enem lokalnem vrhu (§3 spodaj - ista skrb kot pri nas glede večkratnih lokalnih minimumov), če je med njim in drugim vrhom dolina prenizke verjetnosti, da bi jo naključni sprehod kdaj sam prečkal.

Rešitev (Jasra et al., 2007). Poganjaj VEČ verig HKRATI, vsaka na "ohlajeni" različici ciljne gostote $\pi_k(\theta) \propto \pi(\theta)^{1/T_k}$ z različno "temperaturo" T_k ($T_1 = 1$ prava gostota, $T_k > 1$ zgladi/splošči gostoto - lažje preskakuje med vrhovi). Občasno predlagaj IZMENJAVO stanj med sosednjima verigama (sprejeto/zavrnjeno spet po Metropolis-Hastingsovem pravilu (1.1), na razširjeni ciljni gostoti čez vse temperature) - vroča veriga (visok T) lahko "prenese" dober kandidat hladni verigi, ki bi ga sama nikoli našla. Dondelinger uporabi TOČNO to: 10 verig pri različnih temperaturah, eksponentna lestvica temperatur, uravnana med "burn-in" fazo za stopnjo sprejema izmenjav ≈ 0.25 .

Vir: A. Jasra, D. A. Stephens, C. C. Holmes, *On population-based simulation for static inference*, Statistics and Computing 17(3), 2007, 263-279.

1.7 "Beljenje" (whitening) za sklopljene latentne spremenljivke

Problem. Stanja X (GP-jevi vzorci) in hiperparametri φ (lengthscale itd.) so MOČNO sklopljeni - $X \sim \mathcal{N}(0, C_\varphi)$, torej sprememba φ TAKOJ spremeni, katere X sploh imajo smisel. Če bi X in φ vzorčil izmenično (Gibbs), bi vsak korak samo "podrl" prejšnjega - zelo počasno mešanje.

Rešitev (Murray & Adams, 2010). Reparametriziraj: uvedi NEODVISNO $\nu \sim \mathcal{N}(0, I)$ in piši $X = L_{C_\varphi} \nu$, kjer $L_{C_\varphi} L_{C_\varphi}^\top = C_\varphi$ (Choleskyjev faktor - ISTA konstrukcija kot naš `FittedGP.L`!). Ker sta ν in φ SAMA PO SEBI neodvisna (apriorno), lahko φ vzorčiš pri FIKSNEM ν (ne fiksnem X) - premik φ takrat avtomatsko "povleče" tudi X (prek $X = L_{C_\varphi} \nu$) na smiselni nov kraj, brez potrebe, da bi morali oba usklajevati ročno.

Vir: I. Murray, R. P. Adams, *Slice sampling covariance hyperparameters of latent Gaussian models*, NeurIPS 23, 2010.

2. Uporaba na problemu ocenjevanja parametrov ODE

2.1 Ciljna gostota

Oba članka vzorčita iz (variacije) iste skupne gostote - ta je NATANKO tista, ki jo Wenk et al. (2019) matematično korektno izpelje kot Theorem 1 (glej [notes/fgpgm.md](#)-primerljivo diskusijo zgoraj v chatu):

$$p(x, \theta \mid y, \varphi, \gamma, \sigma) \propto \underbrace{p(\theta)}_{\text{prior na } \theta} \cdot \underbrace{\mathcal{N}(x \mid 0, C_\varphi)}_{\text{GP prior na stanje}} \cdot \underbrace{\mathcal{N}(y \mid x, \sigma^2 I)}_{\text{ujemanje s podatki}} \cdot \underbrace{\mathcal{N}(f(x, \theta) \mid Dx, A + \gamma I)}_{\text{gradient-matching člen}} \quad (2.1)$$

Zadnji člen je NATANKO naš residual (2.5) iz [gradient-matching.md](#) - Dx je GP-jevo posteriorno povprečje ODVODA (naš $\hat{x}'(t)$), $f(x, \theta)$ je ODE-jeva desna stran F , A pa GP-jeva posteriorna kovarianca

odvoda (naš `_FittedGP.var_deriv`, le polna kovariančna matrika, ne le diagonala) - γI pa je ODE-stranska toleranca na neujemanje, ki je MI NIMAMO (glej prejšnjo primerjavo v chatu).

2.2 AGM (Dondelinger et al.): dvoblokovna Gibbsova shema + populacijski MCMC

Ne vzorčijo (2.1) v ENEM koraku - razdelijo na BLOKE (Gibbsova shema, §2.1 njihovega članka):

1. $\varphi, \sigma \sim p^*(\varphi, \sigma | y)$ - GP hiperparametri, SVOJ MCMC, SAMO iz podatkov y (brez ODE) - to je Calderhead et al.-ov korak, ki ga AGM kritizira kot "brez povratne zanke", a ga vseeno obdrži kot PRVI blok.
2. $X \sim p(X | y, \sigma, \varphi)$ - stanja, vzorčena iz standardnega GP posteriorja (analitično znana Gaussovka - direktno vzorčenje, ni potreben M-H).
3. $\theta, \gamma \sim p(\theta, \gamma | X, \varphi, \sigma)$ - TO je blok, kjer AGM popravi Calderhead et al.: namesto da bi θ, γ NIKOLI vplivala nazaj na φ, σ, X (enosmeren tok), AGM to zanko zapre (§2.2 njihovega članka) - Metropolis-Hastings na (2.1) (brez y -člena eksplisitno, ker je X že fiksiran iz koraka 2).

Vse to teče znotraj POPULACIJSKEGA MCMC-ja (§1.6 zgoraj): 10 verig, temperature, izmenjalni koraki, plus beljenje (§1.7) za sklopljenost X, φ . Konvergenca: PSRF < 1.1 - pogosto NI dosežena (Calderhead-ov model nikoli, AGM sam pogosto potrebuje deset tisoče korakov).

2.3 FGPGM (Wenk et al.): zaporeden fit + ENA veriga

Bistveno preprostejše (Algorithm 1 v njihovem članku):

1. **Korak 1 (enkrat, pred MCMC-jem):** standardiziraj podatke ($\tilde{y} = (y - \mu_y) / \sigma_y$ - to MI NE delamo), nato max-likelihood fit φ_k, σ_k SAMO iz $\tilde{y}$ (isto kot naš `_fit_gp_ld`) - φ, σ ostaneta FIKSIRANA za ves preostanek postopka (nobene povratne zanke nazaj vanju - to je NAMERNO, glej §2.3 spodaj).
2. **Korak 2:** ENA veriga Metropolis-Hastings, vzorči x IN θ SKUPAJ (po komponentah - za vsako stanje/parameter posebej predlagaj Gaussovo motnjo, sprejmi/zavrni po (1.3) na (2.1), z φ, σ fiksima iz koraka 1 in γ ROČNO nastavljenim (preizkusijo 8 logaritemsko-razporejenih vrednosti med 1 in 10^{-4} , izberejo po prileganju).
3. Zavrzi "burn-in" vzorce, vrni POVPREČJE preostalih ($\mathcal{S}$) kot točkovno oceno - čeprav je cel postopek Bayesovski/MCMC, je KONČNI rezultat, ki ga vrnete, spet ena točka (povprečje posteriorja) - poln nabor vzorcev uporabijo samo za risanje negotovostnih pasov (Fig. 3, 5, 7-11 v njihovem članku).

2.4 Ključna, presenetljiva ugotovitev (§4.1 FGPGM članka)

To je bilo že omenjeno v chatu, tu formalno zapisano: FGPGM-jeva primerjava (MVGM = variacijska metoda + ločen max-likelihood fit hiperparametrov, PROTI AGM = skupno vzorčenje φ, X, θ) pokaže, da SKUPNA optimizacija φ z ostalim (AGM-jev glavni prispevek, §2.2 zgoraj) NI koristna za natančnost - nasprotno, poslabša jo. FGPGM zato φ, σ eksplisitno ZAKLENE po koraku 1, nikoli ju ne pusti nazaj vplivati z θ - to je NAMERNA arhitekturna odločitev, ne pomanjkljivost. To je razlog, da je FGPGM HKRATI hitrejši (35 % manj časa, brez potrebe po prekalkulaciji C_φ ob vsakem koraku) IN natančnejši (do 62 % manjši RMSE) od AGM.

3. Primerjava z našim pristopom

3.1 Kaj je "enakovredno" našemu koraku

Naš `estimate_gradient_matching/estimate_integral_matching` = FGPGM-jev KORAK 1 (zaporeden max-likelihood GP fit) + FGPGM-jev cilj (2.1)-jev zadnji člen (brez γ , brez y -člena, ker mi X NIKOLI ne pustimo prosto - vedno je fiksiran na $\hat{x}(t)$) - MINUS korak 2 (MCMC). Namesto MCMC-ja nad (x, θ) mi ENKRAT poiščemo VRH z `least_squares`, in x NIKOLI ne postane prosta spremenljivka (glej prejšnjo primerjavo v chatu - to je bila naša glavna strukturna razlika od FGPGM/Ramsay et al.).

3.2 Tri stvari, ki jih MCMC reši, mi pa jih rešujemo (ali ne rešujemo) drugače

Neposredna povezava na prejšnji del pogovora (trije LOČENI problemi lokalne Gaussove/kvadratične aproksimacije):

- Robne rešitve** (konstanta pripeta na mejo, npr. `refTemp=22.0`): MCMC na (2.1) TOČNO reprezentira robno omejitev (Metropolis-Hastings predlog, ki bi šel čez mejo, se v π preprosto ovrednoti na 0 - zavrnjen), zato vzorci pravilno pokažejo NESIMETRIČNO gostoto ob robu
 - naša Laplaceova aproksimacija to napačno simetrizira. **MCMC je tu genuinely boljši.**
- Ozke doline/skoraj-singularne smeri**: MCMC vzorci sledijo PRAVI (lahko ukrivljeni, ne nujno eliptični) obliki doline, kolikor daleč jo raziščejo - naša G^{-1} elipsa je samo LOKALNA (2. red) aproksimacija okoli vrha, ki lahko zgreši, kako se dolina dejansko ukrivlja dlje stran. **MCMC je spet boljši, a dražje.**
- Prave večkratne lokalne minimume**: TU je populacijski MCMC (§1.6 zgoraj) SPECIFIČNO zasnovan za to (temperature, izmenjalni koraki eksplicitno pomagajo ubežati enemu vrhu). Naš `least_squares` (en sam tek, en `c0`) nima NOBENE zaščite - to smo v chatu že priznali kot nepreverjeno vrzel.

3.3 Cena

Dondelingerjev članek sam poroča red velikosti: 10^5 MCMC korakov traja $\sim 1000-15000$ sekund (odvisno od metode, njihova Fig. 4), konvergenca ($PSRF < 1.1$) pogosto rabi deset tisoče korakov (ali je sploh NE doseže - Calderhead-ov model nikoli). To je REDI VELIKOSTI dražje od našega ENEGA `least_squares` teka (~15-30 evaluacij do konvergence, ~25s na Bled podatkih - glej prejšnje profiliranje v chatu).

3.4 Primerjalna tabela

	AGM (Dondelinger)	FGPGM (Wenk)	Mi (<code>pybm.estimate.*</code>)
Kaj vrne	vzorci (x, θ)	vzorci, POVPREČJE kot točka	ena točka $\hat{c}$
GP hiperparametri φ	vzorčeni SKUPAJ z θ	fiksirani PRED θ (§2.4 - namerno!)	fiksirani pred θ
x (stanje) med fitanjem θ	prosto (vzorčeno)	prosto (vzorčeno)	FIKSIRANO na $\hat{x}(t)$
γ (ODE-GP toleranca)	vzorčen	ročno pomeđen (8 vrednosti)	nimamo ga
Robne rešitve	pravilno predstavljene	pravilno predstavljene	Laplaceova aprox. jih napačno simetrizira
Večkratni vrhovi	populacijski MCMC ublaži	NE ublaži (ena veriga)	NE ublaži (en <code>least_squares</code> tek)

	AGM (Dondelinger)	FGPGM (Wenk)	Mi (pybm.estimate.*)
Cena na fit	zelo visoka (10^3 - 10^4 €+)	nižja od AGM (-35%), a še vedno MCMC	nizka (~10-30s)
Standardizacija podatkov pred GP fitom	ni omenjena	DA (z-score)	NE (poceni popravek, ki bi ga lahko dodali)

4. Povzetek

1. MCMC/Metropolis-Hastings ni magija - je konstrukcija verige, katere STACIONARNA porazdelitev je (dokazano, prek podrobnega ravnovesja) natanko ciljna gostota, iz katere je težko vzorčiti direktno.
2. AGM in FGPGM vzorčita PRIBLIŽNO isto skupno gostoto (2.1), a se RAZLIKUJETA v tem, ali φ (GP hiperparametre) vzorčita SKUPAJ s θ (AGM) ali FIKSIRATA PRED (FGPGM) - FGPGM-jeva empirična ugotovitev je, da je fiksiranje BOLJŠE, kar posredno VALIDIRA arhitekturo, ki jo mi že uporabljamo (zaporedno, ne skupno).
3. Kar mi NIMAMO in bi lahko poceni dodali: standardizacija podatkov pred GP fitom (FGPGM), γ kot dodaten prost parameter v uteži (glej prejšnjo primerjavo [weight_by_uncertainty](#)).
4. Kar mi NIMAMO in bi bilo DRAGO dodati: prosto (ne fiksirano) stanje x med fitanjem, in kakršnokoli zaščito pred večkratnimi lokalnimi vrhovi (MCMC/populacijski MCMC ali vsaj multi-start).
5. Cena razlike je REDI VELIKOSTI - MCMC dá popolnejšo sliko negotovosti (robovi, ukrivljene doline, večmodalnost), a za ceno 10^2 - 10^3 × počasnejšega fita. Za našo rabo (hitro iterativno primerjanje čez 8 foldov, več struktur, več metod) je to trenutno slab kompromis - za KONČNO, skrbno analizo ENEGA že izbranega modela pa bi bil MCMC pravi naslednji korak.

Literatura

Novi viri, specifični za ta dokument (deljeni viri glej [integral-matching.md](#)/[gradient-matching.md](#)):

1. C. P. Robert, G. Casella. *Monte Carlo Statistical Methods*, 2nd ed. Springer, 2004.
2. W. K. Hastings. "Monte Carlo sampling methods using Markov chains and their applications." *Biometrika* 57, 1970, 97-109.
3. A. Gelman, W. R. Gilks, G. O. Roberts. "Weak convergence and optimal scaling of random walk Metropolis algorithms." *Annals of Applied Probability* 7(1), 1997, 110-120.
4. A. Gelman, D. B. Rubin. "Inference from iterative simulation using multiple sequences." *Statistical Science* 7(4), 1992, 457-472.
5. A. Jasra, D. A. Stephens, C. C. Holmes. "On population-based simulation for static inference." *Statistics and Computing* 17(3), 2007, 263-279.
6. I. Murray, R. P. Adams. "Slice sampling covariance hyperparameters of latent Gaussian models." *NeurIPS* 23, 2010.
7. F. Dondelinger, M. Filippone, S. Rogers, D. Husmeier. "ODE parameter inference using adaptive gradient matching with Gaussian processes." *AISTATS*, 2013.
8. P. Wenk, A. Gotovos, S. Bauer, N. S. Gorbach, A. Krause, J. M. Buhmann. "Fast Gaussian process based gradient matching for parameter identification in systems of nonlinear ODEs." *AISTATS*, 2019.